Statistica Descrittiva

dati: popolazione/campione/training set

- studenti iscritti a statistica nel 25/26
- imagenet → n = numerosità del campione

studenti	imagenet
$n = 253$	$n \simeq 14 \cdot 10^6$
Unità sperimentale = riga foglio excel	Unità sperimentale = immagine

x_ℓ = informazione → variabile

↳ variabile quantitativa con $x_\ell \in \mathbb{R}$, $x_\ell \in \mathbb{R}^d$

x_ℓ = matricola $\in \mathbb{R}$

x_ℓ = immagine $\in \mathbb{R}^{256 \times 256}$

↳ variabile qualitativa $x_\ell \in D$ (dizionario)

x_ℓ = corso di laurea = contenuto semantico)

$x_\ell \in \{$ing. inf., ing. gestionale$\}$

Unità sperimentale = elemento dato base

ℓ = unità sper. $\ell = 1, \dots, n$

x_ℓ = (matricola, nome studente, …) | x_ℓ = (immagine digitale, contenuto semantico

Concetti base:

- → campione {come excel}
- → numerosità del campione
- → unità sperimentale $\ell = 1, \dots, n$ singolo elemento campione
- → variabili:
  - quantitative $x_\ell \in \mathbb{R}$
  - qualitative $x_\ell \in D$ D = Dizionario

$\ell = 1, \dots, n$ variabile → quantitativa ($x_\ell \in \mathbb{R}$) / → qualitativa (singola colonna foglio excel)

x_ℓ

$n = 253$, $\ell = 1, \dots, n$

↳ x_ℓ = corso di studi $x_\ell \in \{\underset{v_1}{\text{gestionale}}, \underset{v_2}{\text{informatica}}, \underset{v_3}{\text{altro}}\}$

↳ x_ℓ = Anno di corso $x_\ell \in \{\underset{v_1}{1}, \underset{v_2}{2}, \underset{v_3}{3}, \underset{v_4}{>3}\}$

· valori distinti della variabile x_ℓ

$x_\ell \in \{v_1, \dots, v_m\}$ $m \leq n$, $v_i \neq v_j$, $i \neq j$

$\#A$ = numero di elementi di A (cardinalità)

$n_1 = \#\{\ell = 1, \dots, n \mid x_\ell = v_1\}$

$n_2 = \#\{\ell = 1, \dots, n \mid x_\ell = v_2\}$

$\vdots$

$n_m = \#\{\ell = 1, \dots, n \mid x_\ell = v_m\}$

$v_1, v_2, \dots, v_m$

$n_1, n_2, \dots, n_m \in \mathbb{N}$

frequenza assoluta $\boxed{n_1 + n_2 + \dots + n_m = n}$

frequenza relativa $\boxed{f_1 = \frac{n_1}{n} \quad f_2 = \frac{n_2}{n} \quad \dots \quad f_m = \frac{n_m}{n}}$ frequenza relativa

$f_1, \dots, f_m \in [0, 1]$ si possono esprimere in percentuale

$$\boxed{f_1 + f_2 + f_3 + \dots + f_m = 1}$$

Esempio:

x_ℓ = corso di studi $\ell = 1, \dots, 253 = n$

$x_\ell \in \{$gest., inf., altro$\}$ = G, I, A → v_1, v_2, v_3

$\boxed{f_i = \frac{n_i}{n}}$ $\boxed{n_i = n \cdot f_i}$

$\boxed{n_1 + n_2 + n_3 = n}$

$\boxed{f_1 + f_2 + f_3 = 1}$

$n_1 = 134$, $n_2 = 111$, $n_3 = 8$ } frequenza assoluta

$f_1 = \frac{134}{253} = 0{,}5296\ldots \simeq 0{,}53 = 53\%$

$f_2 = \frac{111}{253} \simeq 44\%$ $f_3 \simeq 3\%$

Istogrammi a barre

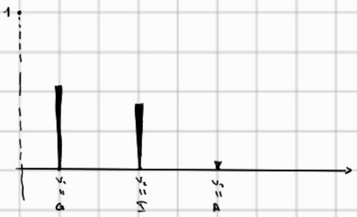

Diagramma a barre

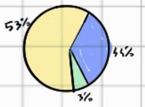

x_ℓ , y_ℓ

x_ℓ = corso di studi $x_\ell = \{G, I, A\}$

y_ℓ = nazionalità $y_\ell = \{$italiana, straniera$\}$

→ freq. assolute, → freq. relative

v_i	n_i	f_i
gestionale	134	53%
informatica	111	44%
altro	8	3%

Tabella a una via

distribuzione marginale di y_ℓ

Tabella a due vie

y_ℓ \ x_ℓ	G (v_1)	I (v_2)	A (v_3)	y_ℓ
italiana	127	101	6	234
stranieri	7	10	2	19
x_ℓ	134	111	8	253

distribuzione marginale di x_ℓ

w_ℓ	n_ℓ
italiana	234
stranieri	19

la tabella a due vie ha più informazioni delle distribuzioni marginali

Tabella a due vie (frequenze relative)

y_ℓ \ x_ℓ	G (v_1)	I (v_2)	A (v_3)	y_ℓ
italiana	50%	40%	2%	92%
stranieri	3%	4%	1%	8%
x_ℓ	53%	44%	3%	100%

$y_\ell = \{w_1, w_2\}$

posso dividere (isolare) in sotto campioni

↳ tipo Nazionalità Italiana o nazionalità straniera

	y_ℓ \ x_ℓ	G (v_1)	I (v_2)	A (v_3)	y_ℓ
w_1	italiana	127	101	6	234
w_2	stranieri	7	10	2	19
	x_ℓ	134	111	8	

y_ℓ \ x_ℓ	G	I	A	y_ℓ
italiana	54%	43%	3%	100%
stranieri	37%	53%	10%	100%

↳ informazione suddivisa in 2 campioni

Frequenze relative del corso di studi data la NAZIONALITÀ

y_ℓ \ x_ℓ	G	I	A	y_ℓ
italiana	127	101	6	234
stranieri	7	10	2	19
x_ℓ	134	111	8	253

caso delle divisioni per colonne

Frequenza relativa della nazionalità dato il corso di studi

y_ℓ \ x_ℓ	G	I	A
italiana	95%	92%	75%
stranieri	5%	9%	25%
x_ℓ	100%	100%	100%

Tabella a due vie campione

y_ℓ \ x_ℓ	G (v_1)	I (v_2)	A (v_3)	y_ℓ
italiana	50%	40%	2%	92%
stranieri	3%	4%	1%	8%
x_ℓ	53%	44%	3%	100%

$x_\ell \in \{v_1, \dots, v_m\}$ $\ell = 1, \dots, n$

$y_\ell \in \{w_1, \dots, w_k\}$ $v_i \to i = 1, \dots, m$

$w_j \to j = 1, \dots, k$

↳ nell'esempio $n = 253$, $k = 2$, $m = 3$

Tabelle a due vie:

→ Frequenze Assolute

x_ℓ \ y_ℓ	w_1	…	w_j	…	w_k
v_1	$n_{1,1}$				
$\vdots$					
v_i	n		$n_{i,j}$		
$\vdots$					
v_m					

$n_{1,1} = \#\{\ell = 1, \dots, n \mid x_\ell = v_1 \quad y_\ell = w_1\}$

$n_{i,j} = \#\{\ell = 1, \dots, n \mid x_\ell = v_i \quad y_\ell = w_j\}$

$f_{i,j} = \frac{n_{i,j}}{n}$ → freq. rel.

$n_{i\cdot} = n_{i1} + \dots + n_{ik}$ $i = 1, \dots, m$

il due punti si dice su quale indice stiamo lavorando

v_i	n_i
v_1	n_1
$\vdots$	$\vdots$
v_m	$n_{m\cdot}$

marginale riga ⇕ tabella una via x_ℓ

$j = 1, \dots, k$

$n_{\cdot j} = n_{1j} + n_{2j} + n_{mj}$

marginale colonna ⇕ tabella a una via y