Statistica Descrittiva

n = numerosità → quanti elementi ha il set di dati analizzato

l = unità sperimentale → elemento del set di dati ($l = 1, \dots, n$)

x_e = informazione, VARIABILE

Variabile
- QUANTITATIVA — $x_e \in \mathbb{R}$, $x_e \in \mathbb{R}^d$ (x_e = matricola → $\mathbb{R}$, x_e = immagine → $\mathbb{R}^{n \times m}$)
- QUALITATIVA — $x_e \in$ ID dizionario (x_e = corso di laurea ∈ {INGINF, GESTIONALE})

Concetti base:
- Campione
- n
- l
- variabili quantitative
- variabili qualitative

PER ESEMPIO → Studenti: Statistica

$n = 253$

$l = 1, \dots, 253$ riga fogli excel

$x_e = \{$ n. matricola (QUANT.), cognome (QUAL.), codice corso (QUANT.) $\}$

Si può avere anche:

x_e = anno di corso → $x_e \in \{1, 2, 3, >3\}$

$x_e \in \{v_1, \dots, v_m\}$, $m \le n$ → $v_i \neq v_j \to i \neq j$; i = valori distinti da 1 a m = $1, \dots, m$

$n_i = \#\{l = 1, \dots, n \mid x_e = v_i\}$

$\#A$ = numero di elementi di A, CARDINALITÀ

$n_1, n_2, \dots, n_m$ frequenza assoluta

$n_1, n_2, \dots, n_m \in \mathbb{N}$ $\quad \boxed{n_1 + n_2 + \dots + n_m = n}$

$f_1 = \frac{n_1}{n}$, $f_2 = \frac{n_2}{n}$, …, $f_m = \frac{n_m}{n}$ frequenza relativa

$f_1, f_2, \dots, f_m \in [0;1]$ → si esprimono in % $\Rightarrow \boxed{f_1 + f_2 + \dots + f_m = 1}$

LE TABELLE

- x_e = corso di studi ∈ {gestionale, informatica, altro}
- y_e = NAZIONALITÀ ∈ {italiana, straniera}

Tabella a UNA via:

v_i	n_i	f_i
G	134	53%
I	111	44%
A	8	3%

Tabella a DUE vie:

y_e \ x_e	G	I	A	y_e
IT	127	101	6	234
S	7	10	2	19
x_e	134	111	8	

distribuzioni marginali

Tabelle a DUE vie (frequenze relative):

y_e \ x_e	G	I	A	y_e
IT	50%	40%	2%	92%
S	3%	4%	1%	8%
x_e	53%	44%	3%	100%

Tabelle a DUE vie (frequenze relative di SOTTOCAMPIONI)

y_e \ x_e	G	I	A	y_e
IT	127	101	6	234 →
S	7	10	2	19 →
x_e	134	111	8	

PROFILO Riga:

y_e \ x_e	G	I	A	Σ
IT	54%	43%	3%	100%
S	37%	53%	10%	100%

PROFILO Colonna:

y_e \ x_e	G	I	A
IT	95%	91%	75%
S	5%	9%	25%
Σ	100%	100%	100%

Indici Statistici:

- Media (campionaria) → $\bar{x}$

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{n_1 \cdot v_1 + n_2 v_2 + \dots + n_m v_m}{n}$$

$= f_1 v_1 + f_2 v_2 + \dots + f_m v_m$

→ valore minimo $\le \bar{x} \le$ valore massimo

→ $y_e = a x_e + b \quad a, b \in \mathbb{R}$, $a \neq 0$ $\quad \bar{y} = a\bar{x} + b$

→ Centratura:

$y_1 = x_1 - \bar{x}$, $y_2 = x_2 - \bar{x}$, …, $y_n = x_n - \bar{x}$

$\bar{y} = \overline{(x - \bar{x})} = \overline{ax + b} = a\bar{x} + b = \bar{x} - \bar{x} = 0$

Oss. 1) $x_e \to x_e - \bar{x} = y_e$ CENTRATURA

2) Se $\bar{x} = 0$ i dati sono a media NULLA o CENTRATI

- Quantile e Mediana:

I quantile → 25%

III quantile → 75%

Definizioni: 0% 25% 50% 75% 100%

$Q_0 = v_1$ = valore minimo

$$Q_i = v_i : \begin{cases} f_1 + f_2 + \dots + f_{i-1} < 25\% \\ f_1 + f_2 + \dots + f_i \ge 25\% \end{cases} \to \text{(subito prima di 25\%)}$$

$$Q_2 = v_i : \begin{cases} f_1 + f_2 + \dots + f_{i-1} < 50\% \\ f_1 + f_2 + \dots + f_i \ge 50\% \end{cases} \text{(subito prima di 50\%)}$$

→ MEDIANA

$Q_3 = v_i$ (subito prima di 75%)

$Q_4 = v_n$ = valore massimo

↓

Box-Plot:

Servono:
- Q_0, Q_1, Q_2, Q_3, Q_4
- $IRQ = Q_3 - Q_1$ (Range Interquantile)
- $a = Q_1 - \frac{3}{2} IRQ$
- $b = Q_3 + \frac{3}{2} IRQ$

Baffo SN: valore più piccolo $\ge a$

Baffo DX: valore più grande $\le b$

Outliner SN: valori $< a$

Outliner DX: valori $> b$

a 0,5% Q_1 Q_2 Q_3 99,5% b

outliner

Indice di dispersione - VARIANZA

Definizione:

$$\sigma^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n}$$ varianza (della popolazione)

$$s^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n-1}$$ varianza (del campione)

$\sigma^2 = \overline{(x - \bar{x})^2}$

$s^2 = \frac{n}{n-1}\sigma^2 = \left(1 + \frac{1}{n-1}\right)\sigma^2$

Se $n \gg 1 \to s^2 \simeq \sigma^2$

→ Quindi: σ deviazione standard popolazione; s deviazione standard campione

Proprietà:

$\to s^2 = \frac{n}{n-1}\sigma^2$

$\to \sigma^2 = \frac{n-1}{n} \cdot s^2$

$\to \sigma^2 = \overline{x^2} - \bar{x}^2$

$\to \overline{x^2} = \frac{x_1^2 + x_2^2 + \dots + x_n^2}{n} = f_1 v_1^2 + \dots + f_m v_m^2$

$\to y_1 = ax_1 + b$, …, $y_n = ax_n + b$ $\quad a, b \in \mathbb{R}$, $a \neq 0$ $\to \sigma_y^2 = a^2\sigma_x^2$ (con $\bar{y} = a\bar{x} + b$)

Coefficiente di Correlazione:

$\bar{x}$ = media, $\bar{y}$ = media

σ_x^2 = varianza, σ_y^2 = varianza

$\sigma_x > 0$ $\quad \sigma_y > 0$

$$\rho_{x,y} = \frac{\overline{(xy)} - \bar{x} \cdot \bar{y}}{\sigma_x \cdot \sigma_y}$$

Oss.: $\sigma_x = 0 \to \sigma_x^2 = 0$

$\Updownarrow$

$(x_1 - \bar{x})^2 = \dots = (x_n - \bar{x})^2 = 0$

$\Updownarrow$

$x_1 = \dots = x_n = \bar{x}$

Proprietà: (COVARIANZA tra x e y)

$$\to \rho_{x,y} = \frac{\frac{1}{n}\left[(x_1 - \bar{x})(y_1 - \bar{y}) + \dots + (x_n - \bar{x})(y_n - \bar{y})\right]}{\sigma_x \cdot \sigma_y}$$

$\to \rho_{x,y} = \rho_{y,x}$

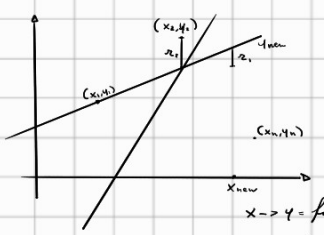
$\to -1 \le \rho_{x,y} \le 1$

$\to \rho_{x,x} = 1$

→ se $z_i = ax_i + b$, …, $z_n = ax_n + b$ $\to \rho_{x,y} = \rho_{z,y}$

→ $\rho_{x,y}$ è un numero puro

Retta Minimi Quadrati



$x \to y$ = funzione

$\hat{y}_n = m x_n + q$ $\quad y = mx + q \cdot f(x)$ $\quad y_{new} = f(x_{new})$

$y_n - \hat{y}_n = z_n$

$\tan\theta = m$: $m > 0$ ↗, $m = 0$ →, $m < 0$ ↘

$\frac{|z_1| + |z_2| + \dots + |z_n|}{n}$ = ERRORE LAPLACE

$\frac{z_1^2 + z_2^2 + \dots + z_n^2}{n}$ = ERRORE LEGGENDRE / GAUSS

MINIMIZZARE

Si chiama retta dei minimi quadrati, la retta $y = m^* x + q^*$ (sono la soluzione del problema minimo)

Teorema: la retta dei minimi quadrati è data da

$$y = \frac{\sigma_y}{\sigma_x} \rho_{x,y} \cdot (x - \bar{x}) + \bar{y}$$

PROBABILITÀ:

Spazio campionario: insieme di tutti i possibili risultati = Ω

Evento: un evento E è un sottoinsieme di Ω ($E \subseteq \Omega$). È una collezione di possibili risultati:



Tipo: (Dado)

E: "numero pari" = $\{2,4,6\}$

F: " " dispari" = $\{1,3,5\}$

→ Dato un evento $E \subseteq \Omega$, se esce il risultato $\omega \in \Omega$:

- $\omega \in E$ — E è accaduto
- $\omega \notin E$ — E NON è accaduto

→ Ω: evento CERTO ; $\emptyset$ evento IMPOSSIBILE

→ Siano E e F due eventi:

- $E \cap F$ è un evento CONGIUNTO
  ↳ $\{\omega \in \Omega \mid \omega \in E \text{ e } \omega \in F\}$
- $E \cup F$ è un evento UNIONE
  ↳ $\{\omega \in \Omega \mid \omega \in E \text{ o } \omega \in F\}$

→ Dato un evento $E \subseteq \Omega$, $\mathbb{P}[E]$ è la PROBABILITÀ dell'evento E, tale che:

- $\mathbb{P}[\Omega] = 1 = 100\%$
- $0 \le \mathbb{P}[E] \le 1$
- se E e F sono eventi DISGIUNTI ($E \cap F = \emptyset$) allora $\mathbb{P}[E \cup F] = \mathbb{P}[E] + \mathbb{P}[F]$

Proprietà:

- $\mathbb{P}[\emptyset] = 0$
- $E \subseteq F \rightarrow \mathbb{P}[E] \le \mathbb{P}[F]$
- E e F eventi → $\mathbb{P}[E \cup F] = \mathbb{P}[E] + \mathbb{P}[F] - \underbrace{\mathbb{P}[E \cap F]}_{\text{è } 0 \text{ se } E \cap F = \emptyset}$
- $E_1, \dots, E_n$ famiglia di insiemi a due a due disgiunti ($E_i \cap E_j = \emptyset$ con $i \neq j$) allora $\mathbb{P}[E_1 \cup \dots \cup E_n] = \mathbb{P}[E_1] + \dots + \mathbb{P}[E_n]$
- E_1, E_2, E_3 eventi: $\mathbb{P}[E_1 \cup E_2 \cup E_3] =$
  Principio di inclusione-esclusione
  $= \mathbb{P}[E_1] + \mathbb{P}[E_2] + \mathbb{P}[E_3] - (\mathbb{P}[E_1 \cap E_2] + \mathbb{P}[E_1 \cap E_3] + \mathbb{P}[E_2 \cap E_3]) + \mathbb{P}[E_1 \cap E_2 \cap E_3]$
- $\mathbb{P}[\bar{E}] = 1 - \mathbb{P}[E]$

SPAZIO DI PROBABILITÀ FINITO: uno spazio di probabilità si dice FINITO se lo spazio campionario Ω ha un numero finito di elementi

$\Omega = \{\omega_1, \dots, \omega_N\}$ $\omega_i \neq \omega_j$ $i \neq j$, $N \in \mathbb{N}$

La probabilità di un evento è nota conoscendo la probabilità dei possibili risultati:

ω	$\mathbb{P}[\{\omega\}]$
ω_1	p_1
ω_2	p_2
⋮	⋮
ω_N	p_N

distribuzione di probabilità

$p_1, \dots, p_N \ge 0$, $p_1 + \dots + p_N = 1$ → $0 \le p_i \le 1$, $i = 1, \dots, N$

Qui è necessario un esempietto veloce, con un dado che ha il doppio della probabilità che esca il "2". Qual'è la probabilità che esca un numero pari?

ω	$\mathbb{P}[\{\omega\}]$	
1	p	$1/7$
2	$2p$	$2/7$
3	p	$1/7$
4	p	$1/7$
5	p	$1/7$
6	p	$1/7$

$p \ge 0$ $p = 1/7$

$7p = 1$

E: "numero pari" = $\{2,4,6\}$

$\mathbb{P}[E] = 4/7 \in [0,1]$

$\#E = 3$

$\#\Omega = 6$

$\mathbb{P}[E] = 3/7$

Uno spazio di probabilità finito si dice EQUIPROBABILE se tutti i risultati hanno la stessa probabilità

Fattoriale:

$n \in \mathbb{N}$ $n! = 1 \cdot 2 \cdot \dots \cdot n = (n-1)! \cdot n$

$0! = 1$

Coefficiente binomiale: $\binom{5}{3} = \frac{5!}{3!\,2!} = \frac{120}{6 \cdot 2} = 10$

$n, k \in \mathbb{N}$

$\binom{n}{k} = \frac{n!}{k!\,(n-k)!}$

CALCOLO COMBINATORIO

n oggetti distinti $n \in \mathbb{N}$

k estrazioni $k \in \mathbb{N}$

Modalità d'estrazione

→ estrazione senza ripetizioni = risultati diversi tra di loro

→ estrazione con ripetizione = risultati possono essere uguali

Modalità di Memorizzazione del risultato

→ si tiene conto dell'ordine = PERMUTAZIONI

→ non si tiene conto dell'ordine = COMBINAZIONI

Il calcolo combinatorio conta in quanti modi posso fare le estrazioni:

	Conta Ordine — Permutazioni	Non Conta Ordine — Combinazioni
Senza Ripetizioni	$k \le n$ $\frac{n!}{(n-k)!}$ $k = n \rightarrow \#\text{modi} = n!$	$k \le n$ $\#\text{modi} \left(\binom{n}{k}\right) = \frac{n!}{k!\,(n-k)!}$
Con Ripetizioni	$k \in \mathbb{N}$ numero modi $= n^k = \underbrace{n \cdot n \cdot \dots \cdot n}_{k \text{ fattori}}$	$k \in \mathbb{N}$ $\#\text{modi} \left(\binom{n+k-1}{k}\right) = \frac{(n+k-1)!}{k!\,(n-1)!}$

Proprietà del Coefficiente Binomiale

1) $\binom{n}{n} \cdot \binom{n}{0} = 1$
2) $\binom{n}{k} = \binom{n}{n-k}$
3) $\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$
4) $(a+b)^n = \sum_{k=0}^{n} a^k b^{n-k}$

$(a+b)^2 = a^2 + 2ab + b^2$

$(a+b)^3 = \binom{3}{0}a^0b^3 + \binom{3}{1}a^1b^2 + \binom{3}{2}a^2b^1 + \binom{3}{3}a^3b^0 = \binom{3}{0}a^0b^3 + \binom{3}{1}a^1b^2 + \binom{3}{2}a^2b^1 + \binom{3}{3}a^3b^0$

$k = 0, \dots, 3$, $n = 3$

$= a^3 + 3a^2b + 3ab^2 + b^3 = 1b^3 + 3ab^2 + 1a^3$

12 R 8 B → ne estraggo 4 no rip. — Probabilità di ottenere 2R e 2B

$\mathbb{P}[E] = \frac{\#\text{casi favorevoli}}{\#\text{casi possibili}} = \frac{\binom{12}{2} \cdot \binom{8}{2}}{\binom{20}{4}} \simeq 38\%$ (NO RIP. NO ORD; $\frac{12 \cdot 11}{2!}$, $\frac{8 \cdot 7}{2!}$, $\frac{20 \cdot 19 \cdot 18 \cdot 17}{4!}$)

Mazzo 52 carte — 4 semi — 13 valori

DOPPIA COPPIA:

Casi favorevoli / Casi possibili

↳ $\binom{52}{5}$ ← pescare 5 carte da un mazzo di 52

Doppia Coppia → 2 carte dello stesso valore, altre 2 carte di un altro valore uguale + 1 carta spinta di un valore ancora diverso

Quindi Casi favorevoli:

→ $\binom{13}{2}$: Selezione i valori delle due coppie
Ci sono 13 valori nel mazzo (A, 2, 3, …, K, A, 2, 3)
Dobbiamo prenderne 2, come "Re e 7"
Uniamo il coefficiente binomiale perché l'ordine non conta

→ 2 volte $\binom{4}{2}$ Selezione dei semi delle coppie

→ 44 Selezionare la carta rimanente $\binom{52-8}{1}$

Quindi: $\mathbb{P}[\text{doppia coppia}] = \frac{\binom{13}{2}\binom{4}{2}\binom{4}{2}44}{\binom{52}{5}} \simeq 5\%$

PROBABILITÀ CONDIZIONATA:

Estraggo due carte da un mazzo di 52 carte (4 semi).
Qual'è la probabilità di ottenere due fiori?

$\mathbb{P}[\text{"2 fiori"}] = \frac{\binom{13}{2}}{\binom{52}{2}} = \frac{13 \cdot 12}{52 \cdot 51}$

$\mathbb{P}[\text{2 FIORI}] = \mathbb{P}[(1° \text{ FIORE}) \cap (2° \text{ FIORE})] = \frac{13}{52} \cdot \frac{12}{51}$

$\mathbb{P}[E] \frac{13}{52} = \frac{1}{4}$ $\mathbb{P}[F] = \frac{51 \cdot 13}{52 \cdot 51} = \frac{13}{52}$

DEF. (probabilità condizionata): dati due eventi E, F

$\mathbb{P}[F|E] = \frac{\mathbb{P}[E \cap F]}{\mathbb{P}[E]}$

↑ prob. condizionata di F dato E

↳ se $\mathbb{P}[E] = 0$ → $\mathbb{P}[E \cap F] = 0$ ($E \cap F \subseteq E$)

Regola del prodotto

$\mathbb{P}[E \cap F] = \mathbb{P}[E] \cdot \mathbb{P}[F|E]$ succede prima E e poi F

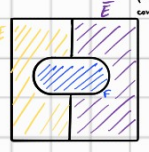
- Proprietà (regola della catena)
  → dati due eventi E e F
  $\mathbb{P}[E \cap F] = \mathbb{P}[E] \cdot \mathbb{P}[F|E]$
  → dato una famiglia di eventi $E_1, \dots, E_n$
  $\mathbb{P}[E_1 \cap E_2 \cap \dots \cap E_n] = \mathbb{P}[E_1] \cdot \mathbb{P}[E_2|E_1] \cdot \mathbb{P}[E_3|E_1 \cap E_2] \cdot \dots \cdot \mathbb{P}[E_n|E_1 \cap E_2 \cap \dots \cap E_{n-1}]$

FORMULA DELLA PROBABILITÀ TOTALE

→ Dati 2 eventi E e F

$\mathbb{P}[F] = \mathbb{P}[E] \cdot \mathbb{P}[F|E] + \mathbb{P}[\bar{E}] \cdot \mathbb{P}[F|\bar{E}]$

($\mathbb{P}[F|\bar{E}]$: probabilità condizionata; $\bar{E}$: evento opposto)





Una famiglia $E_1, \dots, E_n$ di eventi a due a due disgiunti e un evento F, con $\Omega = E_1 \cup E_2 \cup \dots \cup E_n$

$\mathbb{P}[F] = \mathbb{P}[E_1] \cdot \mathbb{P}[F|E_1] + \mathbb{P}[E_2] \cdot \mathbb{P}[F|E_2] + \dots + \mathbb{P}[E_n] \cdot \mathbb{P}[F|E_n]$

FORMULA DI BAYES

$\mathbb{P}[E \cap F] = \mathbb{P}[E] \cdot \mathbb{P}[F|E]$
$\mathbb{P}[F \cap E] = \mathbb{P}[F] \cdot \mathbb{P}[E|F]$

$$\mathbb{P}[E|F] = \frac{\mathbb{P}[E] \cdot \mathbb{P}[F|E]}{\mathbb{P}[F]}$$

↳ Caso Generale

- data una famiglia di eventi $E_1, \dots, E_n$ tale che:
  - $\to E_i \cap E_j = \emptyset$ con $i \neq j$
  - $\to \Omega = E_1 \cup \dots \cup E_n$

$$\mathbb{P}[E_i|F] = \frac{\mathbb{P}[E_i] \cdot \mathbb{P}[F|E_i]}{\mathbb{P}[F]}$$