Statistica

Appunti del corso · a.a. 2026/27 · Mobius

Appunti personali e non ufficiali, rivisti e confrontati con il programma ufficiale del corso. Non sostituiscono le lezioni né i testi consigliati.

Indice

1. Statistica descrittiva
2. Probabilità e variabili aleatorie
3. Valori attesi, leggi notevoli e teoremi limite
4. Inferenza: stima, intervalli e test

1 · Statistica descrittiva

In questo modulo. Non servono prerequisiti oltre l'algebra delle scuole superiori e la notazione di sommatoria. Si impara a descrivere un insieme di dati: come si organizzano in tabelle e grafici, come si riassumono con pochi numeri che dicono dove stanno (media, mediana, quantili) e quanto sono sparsi (varianza, deviazione standard, scarto interquartile), come si legge il boxplot e come si misura la relazione fra due variabili con la covarianza, la correlazione e la retta dei minimi quadrati. È la parte "descrittiva" della statistica: non si fanno ancora affermazioni sulla popolazione da cui i dati vengono, cosa che richiede la probabilità (moduli 2 e 3) e l'inferenza (modulo 4).

1.1 Dati, unità e variabili

Un insieme di dati è una raccolta di osservazioni, organizzata di solito come un foglio di calcolo: ogni riga è un'**unità sperimentale** (uno studente, un'immagine, un pezzo prodotto), ogni colonna è una **variabile**, cioè un'informazione rilevata su ciascuna unità. Le unità si indicano con un indice $\ell = 1, \dots, n$, dove n è la **numerosità** del campione, e il valore della variabile sull'unità ℓ si scrive x_ℓ.

Le dimensioni possono essere molto diverse: gli iscritti al corso di Statistica nel 2025/26 erano $n = 253$, mentre un archivio pubblico di immagini come ImageNet ne contiene circa $14 \cdot 10^6$.

> **Variabili quantitative e qualitative**
>
> Una variabile è **quantitativa** se assume valori numerici, $x_\ell \in \mathbb{R}$ (o, più in generale, vettori di numeri: una matrice, un'immagine digitale come tabella di pixel). È **qualitativa** (o categorica) se assume valori in un insieme finito di modalità non numeriche, un "dizionario" D: il corso di laurea, la nazionalità, il colore degli occhi.

La distinzione decide quali operazioni hanno senso: la media dell'altezza è un numero utile, la "media del corso di laurea" no. Una variabile qualitativa si può codificare con numeri (1 = gestionale, 2 = informatica), ma i codici restano etichette.

1.2 Frequenze e grafici

Siano $v_1, \dots, v_m$ i valori distinti che la variabile assume sul campione, con $m \le n$. La **frequenza assoluta** di v_i è il numero di unità che hanno quel valore, e la **frequenza relativa** è la stessa cosa divisa per n:

$$n_i = \#\{\ell = 1, \dots, n \mid x_\ell = v_i\}, \qquad f_i = \frac{n_i}{n}.$$

Si ha $n_1 + \cdots + n_m = n$ e $f_1 + \cdots + f_m = 1$; le frequenze relative si scrivono spesso in percentuale.

> **Corso di laurea degli iscritti**
>
> Dei 253 iscritti, 134 sono di ingegneria gestionale, 111 di informatica e 8 di altri corsi. Le frequenze relative sono
>
> $$f_1 = \frac{134}{253} \approx 53\%, \qquad f_2 = \frac{111}{253} \approx 44\%, \qquad f_3 = \frac{8}{253} \approx 3\%.$$

La **tabella a una via** elenca v_i, n_i, f_i. Per una variabile qualitativa i grafici usuali sono il **diagramma a barre**, con una barra di altezza f_i per ogni modalità, e il **diagramma a torta**, con settori di ampiezza proporzionale a f_i (nell'esempio: $0{,}53 \cdot 360^\circ \approx 191^\circ$ per gestionale). Per una variabile quantitativa con pochi valori distinti si usa un diagramma a bastoncini sopra i punti v_i dell'asse reale.

Aggiunta in revisione · fonte: Ross, *Introduzione alla statistica* (STA-07)

La **moda** è il valore (o la modalità) con la frequenza più alta: nell'esempio è "gestionale". È l'unico indice di posizione che ha senso anche per una variabile qualitativa, e può non essere unica.

Il **diagramma di Pareto** è un diagramma a barre con le modalità ordinate per frequenza decrescente, a cui si sovrappone la linea delle frequenze cumulate (53%, 97%, 100% nell'esempio). Si usa per vedere quali poche categorie spiegano la maggior parte dei casi, per esempio quali tipi di guasto causano la maggior parte dei fermi di un impianto.

1.3 Tabelle a due vie

Quando su ogni unità si rilevano due variabili qualitative x (con modalità $v_1, \dots, v_m$) e y (con modalità $w_1, \dots, w_k$), si contano le coppie:

$$n_{ij} = \#\{\ell \mid x_\ell = v_i,\ y_\ell = w_j\}, \qquad f_{ij} = \frac{n_{ij}}{n}.$$

La **tabella a due vie** (o di contingenza) ha una riga per ogni v_i e una colonna per ogni w_j. Sommando lungo le righe e le colonne si ottengono le **distribuzioni marginali**, cioè le tabelle a una via delle due variabili separate:

$$n_{i\cdot} = n_{i1} + \dots + n_{ik}, \qquad n_{\cdot j} = n_{1j} + \dots + n_{mj}.$$

Il punto al posto di un indice ricorda su quale indice si è sommato.

Corso di laurea e nazionalità

	Gestionale	Informatica	Altro	Totale
Italiani	127	101	6	234
Stranieri	7	10	2	19
Totale	134	111	8	253

In frequenze relative: $f_{11} = \frac{127}{253} \approx 50\%$, e così via. L'ultima riga è la distribuzione marginale del corso di laurea (53%, 44%, 3%), l'ultima colonna quella della nazionalità (92%, 8%).

La tabella a due vie contiene più informazione delle due marginali: dice come le variabili si combinano. Per confrontare gruppi di dimensioni diverse si usano i **profili**, cioè le frequenze relative calcolate dentro una riga o dentro una colonna.

Profili riga e colonna

Il **profilo della riga** i è la distribuzione di y nel sottocampione delle unità con $x = v_i$: $f_{j|i} = \frac{n_{ij}}{n_{i\cdot}}$. Il **profilo della colonna** j è la distribuzione di x fra le unità con $y = w_j$: $f_{i|j} = \frac{n_{ij}}{n_{\cdot j}}$. Ogni profilo somma a 1.

Nell'esempio, il profilo della riga "stranieri" è $\frac{7}{19} \approx 37\%$, $\frac{10}{19} \approx 53\%$, $\frac{2}{19} \approx 10\%$, contro il 54%, 43%, 3% degli italiani: fra gli stranieri la quota di informatici è più alta. Il profilo della colonna "altro" dice che fra gli iscritti ad altri corsi gli stranieri sono il 25%, contro il 5% fra i gestionali e il 9% fra gli informatici.

Dalle definizioni segue la **regola del prodotto**: la frequenza congiunta è il profilo per la marginale,

$$f_{ij} = f_{j|i}\, f_{i\cdot} = f_{i|j}\, f_{\cdot j}.$$

È la versione per le frequenze della regola del prodotto per le probabilità del modulo 2.

1.4 Indici di posizione

Da qui in poi la variabile è quantitativa, con valori distinti ordinati $v_1 < v_2 < \dots < v_m$.

Media empirica

$$\bar{x} = \frac{x_1 + \cdots + x_n}{n} = \frac{n_1 v_1 + \cdots + n_m v_m}{n} = f_1 v_1 + \cdots + f_m v_m.$$

La seconda forma si usa quando i dati sono dati come tabella di frequenze. Due proprietà immediate: la media sta fra il valore minimo e il massimo, $v_1 \le \bar{x} \le v_m$; e se si trasformano i dati linearmente, $y_\ell = a x_\ell + b$, la media si trasforma allo stesso modo, $\bar{y} = a\bar{x} + b$. Con $a = 1$ e $b = -\bar{x}$ si ottengono i dati **centrati** $y_\ell = x_\ell - \bar{x}$, che hanno media nulla.

La media è sensibile ai valori estremi. Con i dati $1, 2, \ldots, 10$ la media è $\frac{55}{10} = 5{,}5$; se il 10 diventa 100 la media sale a $\frac{145}{10} = 14{,}5$, un valore che non descrive nessuno dei dati. Un indice più stabile è la mediana, che si definisce con le frequenze cumulate.

La **funzione di distribuzione cumulata empirica** è

$$F(x) = \frac{\#\{\ell \mid x_\ell \le x\}}{n},$$

cioè la frazione di dati minori o uguali a x. È una funzione a gradini, nulla prima di v_1, uguale a 1 dopo v_m, con un salto di altezza f_i in ogni v_i; nei punti v_i vale $f_1 + \cdots + f_i$.

Quantili, percentili, quartili

Per $q \in (0, 1]$, il **quantile** di ordine q è il primo valore v_i in cui la frequenza cumulata raggiunge q:

$$x_q = v_i \quad \text{se} \quad f_1 + \cdots + f_{i-1} < q \le f_1 + \cdots + f_i.$$

Il k-esimo **percentile** è il quantile di ordine $q = \frac{k}{100}$. I **quartili** sono $Q_1 = x_{1/4}$, $Q_2 = x_{1/2}$ e $Q_3 = x_{3/4}$; si pone anche $Q_0 = v_1$ (minimo) e $Q_4 = v_m$ (massimo). Il quartile Q_2 è la **mediana**.

Quindi almeno il 25% dei dati è minore o uguale a Q_1, almeno metà dei dati è minore o uguale alla mediana, e così via. Con i dati $1, \ldots, 10$ (frequenza $\frac{1}{10}$ ciascuno) la cumulata raggiunge $\frac{1}{2}$ in 5: la mediana è 5, e resta 5 anche se il 10 diventa 100. La mediana è **robusta** rispetto ai valori anomali, la media no.

Altre convenzioni

Esistono più definizioni di quantile, che differiscono solo quando la cumulata cade esattamente su q o fra due valori; molti programmi interpolano (con $1, \ldots, 10$ danno mediana 5,5). Nel corso si usa la definizione sopra.

1.5 Boxplot

Il **boxplot** (diagramma a scatola) riassume la distribuzione in un solo disegno, sopra l'asse dei valori:

- la **scatola** va da Q_1 a Q_3 e contiene il 50% centrale dei dati, con una linea sulla mediana;
- l'ampiezza della scatola è lo **scarto interquartile** $\mathrm{IQR} = Q_3 - Q_1$;
- i **baffi** partono dai lati della scatola e arrivano al dato più piccolo e al più grande che stanno entro i limiti

$$a = Q_1 - \tfrac{3}{2}\,\mathrm{IQR}, \qquad b = Q_3 + \tfrac{3}{2}\,\mathrm{IQR};$$

- i dati fuori da $[a, b]$ si disegnano come punti isolati: sono i **valori anomali** (*outlier*).

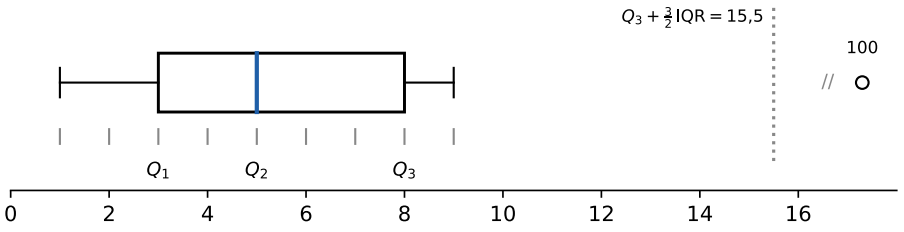


Figura 1.1 · Boxplot dei dati 1, 2, …, 9, 100.

Per i dati $1, \dots, 9, 100$ si ha $Q_1 = 3$, $Q_2 = 5$, $Q_3 = 8$, $\mathrm{IQR} = 5$ e $b = 8 + 7{,}5 = 15{,}5$: il baffo destro arriva a 9 e il 100 è un valore anomalo (figura 1.1). La posizione della mediana dentro la scatola e la lunghezza dei baffi dicono se la distribuzione è simmetrica o sbilanciata da un lato.

1.6 Indici di dispersione

Due gruppi di dati possono avere la stessa media ed essere molto diversi. Se uno studente ha preso dieci volte 24 e un altro cinque volte 18 e cinque volte 30, la media è 24 per entrambi, ma i voti del secondo sono molto più sparsi. Gli indici di dispersione misurano quanto.

I più semplici sono il **campo di variazione** (*range*) $v_m - v_1$, che dipende solo dai due estremi, e lo scarto interquartile IQR, che è robusto come la mediana.

> **Varianza e deviazione standard**
>
> La **varianza** (della popolazione) e la **varianza campionaria** sono
>
> $$\sigma^2 = \frac{1}{n}\sum_{\ell=1}^{n}(x_\ell - \bar{x})^2, \qquad s^2 = \frac{1}{n-1}\sum_{\ell=1}^{n}(x_\ell - \bar{x})^2.$$
>
> Le loro radici σ e s sono la **deviazione standard** della popolazione e del campione.

La varianza è la media dei quadrati degli scarti dalla media: si eleva al quadrato perché gli scarti, sommati, darebbero sempre zero. Le due versioni sono legate da $s^2 = \frac{n}{n-1}\sigma^2 = \left(1 + \frac{1}{n-1}\right)\sigma^2$ e per n grande sono quasi uguali. Il motivo del denominatore $n - 1$ si vedrà nel modulo 4: s^2 è lo stimatore corretto della varianza di una popolazione.

La varianza si misura nel quadrato dell'unità dei dati (m², kg²), la deviazione standard nella stessa unità: per questo si usa la seconda per descrivere la dispersione. Nell'esempio dei voti, il primo studente ha $\sigma = 0$; per il secondo ogni scarto vale ± 6, quindi $\sigma^2 = 36$, $\sigma = 6$, $s^2 = 40$.

> **Proprietà della varianza**
>
> - $\sigma^2 = \overline{x^2} - \bar{x}^2$, dove $\overline{x^2} = \frac{1}{n}\sum x_\ell^2$ è la media dei quadrati;
> - se $y_\ell = a x_\ell + b$, allora $\sigma_y^2 = a^2 \sigma_x^2$ e $\sigma_y = |a|\,\sigma_x$;
> - $\sigma^2 = 0$ se e solo se tutti i dati sono uguali.

Dimostrazione dell'ultima. Se $\sigma^2 = 0$, la somma dei quadrati $(x_\ell - \bar{x})^2$ è nulla, e una somma di termini non negativi è nulla solo se lo è ogni termine: $x_\ell = \bar{x}$ per ogni ℓ. $\square$

La prima formula è quella comoda per il calcolo: basta la media dei dati e quella dei loro quadrati. La seconda dice che spostare i dati non cambia la dispersione, cambiare scala sì.

> **Aggiunta in revisione · fonte: Ross, *Introduzione alla statistica* (STA-09)**
>
> Il **coefficiente di variazione** $\mathrm{CV} = \frac{\sigma}{|\bar{x}|}$ (per $\bar{x} \neq 0$) misura la dispersione in rapporto alla media ed è un numero puro, quindi permette di confrontare la variabilità di grandezze con unità o ordini di grandezza diversi. Per i voti del secondo studente $\mathrm{CV} = \frac{6}{24} = 0{,}25$.

1.7 Covarianza, correlazione e retta dei minimi quadrati

Siano ora rilevate su ogni unità due variabili quantitative, con dati $(x_1, y_1), \dots, (x_n, y_n)$, medie $\bar{x}$, $\bar{y}$ e deviazioni standard $\sigma_x, \sigma_y > 0$.

Covarianza e coefficiente di correlazione

$$\sigma_{xy} = \frac{1}{n}\sum_{\ell=1}^{n}(x_\ell - \bar{x})(y_\ell - \bar{y}) = \overline{xy} - \bar{x}\,\bar{y}, \qquad \rho_{xy} = \frac{\sigma_{xy}}{\sigma_x\,\sigma_y}.$$

Il segno della covarianza dice se i due scarti tendono ad avere lo stesso segno (valori grandi di x con valori grandi di y) o segno opposto. La covarianza ha come unità il prodotto delle due unità (metri per chilogrammi, per esempio); dividendo per le deviazioni standard si ottiene il **coefficiente di correlazione**, che è un numero puro.

Proprietà del coefficiente di correlazione

- $\rho_{xy} = \rho_{yx}$ e $\rho_{xx} = 1$;
- $-1 \le \rho_{xy} \le 1$;
- $|\rho_{xy}| = 1$ se e solo se i punti (x_ℓ, y_ℓ) stanno tutti su una retta (con pendenza dello stesso segno di ρ);
- se $z_\ell = a x_\ell + b$ con $a > 0$, allora $\rho_{zy} = \rho_{xy}$: il coefficiente non dipende dalle unità di misura.

Il coefficiente misura quindi la relazione **lineare** fra le variabili: vicino a ± 1 i punti sono vicini a una retta, vicino a 0 non c'è relazione lineare (ma ce ne può essere una di altro tipo, per esempio una parabola).

Retta dei minimi quadrati. Si vuole una retta $y = mx + q$ che descriva come y dipende da x, per esempio per prevedere il valore di y su una nuova unità di cui si conosce solo x. Per ogni dato si definisce il **residuo** $r_\ell = y_\ell - (m x_\ell + q)$, la distanza verticale fra il punto e la retta. Si possono minimizzare due tipi di errore medio:

$$\frac{|r_1| + \cdots + |r_n|}{n} \text{ (errore di Laplace)}, \qquad \frac{r_1^2 + \cdots + r_n^2}{n} \text{ (errore di Legendre-Gauss)}.$$

Il secondo porta a un problema con una soluzione esplicita.

Retta dei minimi quadrati

La retta che rende minima la somma dei quadrati dei residui è

$$y = \bar{y} + \rho_{xy}\frac{\sigma_y}{\sigma_x}(x - \bar{x}), \qquad \text{cioè} \quad m = \frac{\sigma_{xy}}{\sigma_x^2}, \quad q = \bar{y} - m\bar{x}.$$

La retta passa per il punto medio $(\bar{x}, \bar{y})$ e ha pendenza dello stesso segno della correlazione.

Aggiunta in revisione · fonte: Ross, *Introduzione alla statistica*; Devore, *Probability and Statistics for Engineering and the Sciences* (STA-11)

Coefficiente di determinazione. La variabilità totale di y si scompone in una parte spiegata dalla retta e una residua:

$$\sum (y_\ell - \bar{y})^2 = \sum (\hat{y}_\ell - \bar{y})^2 + \sum r_\ell^2, \qquad \hat{y}_\ell = m x_\ell + q.$$

Il rapporto $R^2 = 1 - \frac{\sum r_\ell^2}{\sum (y_\ell - \bar{y})^2}$ è la frazione della variabilità di y spiegata dalla retta; per la retta dei minimi quadrati vale $R^2 = \rho_{xy}^2$. Un R^2 vicino a 1 indica un buon adattamento.

Analisi dei residui. I residui della retta dei minimi quadrati hanno somma nulla. Disegnati in funzione di x, devono apparire come una nuvola senza struttura attorno a zero; se mostrano una curva o una dispersione che cresce con x, il modello lineare non è adeguato anche quando R^2 è alto.

Aggiunta in revisione · fonte: Newbold, Carlson, Thorne, *Statistica* (STA-10)

Paradosso di Simpson. Una relazione che vale in ogni sottogruppo può invertirsi quando i gruppi si uniscono. Due reparti ammettono candidati: nel reparto A sono ammessi 80 uomini su 100 (80%) e 18 donne su 20 (90%); nel reparto B 5 uomini su 20 (25%) e 30 donne su 100 (30%). In tutti e due i reparti le donne sono ammesse in proporzione maggiore, ma in totale sono ammessi 85 uomini su 120 (71%) e 48 donne su 120 (40%). Il motivo è una terza variabile: le donne hanno fatto domanda soprattutto al reparto B, dove si ammette di meno. Prima di trarre conclusioni da una tabella aggregata conviene guardare i profili nei sottogruppi.

Esempi ed esercizi svolti

Esercizio 1 (genere e colore degli occhi). A 50 persone si chiedono genere (F, M) e colore degli occhi (azzurri A, verdi V, castani C):

	A	**V**	**C**	**Totale**
F	5	8	7	20
M	4	6	20	30
Totale	9	14	27	50

Le frequenze relative congiunte sono, per la riga F, 10%, 16%, 14% (totale 40%) e per la riga M 8%, 12%, 40% (totale 60%); le marginali del colore sono 18%, 28%, 54%. I profili riga: fra le donne 25% A, 40% V, 35% C; fra gli uomini 13%, 20%, 67%. I profili colonna: fra chi ha gli occhi azzurri il 56% sono donne, fra i verdi il 57%, fra i castani il 26%. Le frequenze congiunte direbbero che le donne con occhi azzurri sono “poche” (10%), ma è perché le donne sono il 40% del campione: i profili correggono questo effetto.

Esercizio 2 (un test diagnostico). Una malattia rara colpisce l’1% della popolazione. Un test ha il 10% di falsi positivi (sani che risultano positivi) e il 20% di falsi negativi (malati che risultano negativi). Su 1000 persone ci si aspettano 10 malati, di cui 8 positivi e 2 negativi, e 990 sani, di cui 99 positivi e 891 negativi:

	Positivo	**Negativo**	**Totale**
Malato	8	2	10
Sano	99	891	990
Totale	107	893	1000

Se il test è positivo, la frazione di malati è il profilo della colonna “positivo”: $\frac{8}{107} \approx 7{,}5\%$. Un positivo su più di dieci è davvero malato, perché i sani sono così tanti che anche il 10% di errori produce molti più positivi dei malati. Lo stesso calcolo, fatto con le probabilità, è la formula di Bayes del modulo 2.

Esercizio 3 (quartili e percentili da una tabella). I dati hanno valori e frequenze relative

v_i	**1**	**4**	**5**	**8**	**9**	**10**	**12**	**15**
f_i	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{12}$	$\frac{1}{6}$	$\frac{1}{12}$	$\frac{1}{6}$	$\frac{1}{12}$	$\frac{1}{12}$
cumulata	17%	33%	42%	58%	67%	83%	92%	100%

La cumulata raggiunge il 25% in 4, il 50% in 8, il 75% in 10: $Q_1 = 4$, $Q_2 = 8$, $Q_3 = 10$. Il 10° percentile è 1, il 30° è 4, il 90° è 12. La media è $\sum f_i v_i = \frac{29}{4} = 7{,}25$, un po’ sotto la mediana.

Esercizio 4 (correlazione e retta da una tabella a due vie). Su 10 unità si rilevano $x \in \{1, 2\}$ e $y \in \{-1, 0, 1\}$, con frequenze assolute

	$y = -1$	$y = 0$	$y = 1$	**Totale**
$x = 1$	1	2	3	6
$x = 2$	3	1	0	4
Totale	4	3	3	10

Le medie sono $\bar{x} = \frac{6+8}{10} = 1{,}4$ e $\bar{y} = \frac{-4+3}{10} = -0{,}1$. La media dei prodotti somma xy per ogni casella pesato con la sua frequenza: $\overline{xy} = \frac{1\cdot(-1)\cdot 1 + 1\cdot 1\cdot 3 + 2\cdot(-1)\cdot 3}{10} = -0{,}4$. Quindi

$$\sigma_{xy} = -0{,}4 - 1{,}4 \cdot (-0{,}1) = -0{,}26.$$

Per le varianze: $\overline{x^2} = 2{,}2$, $\sigma_x^2 = 2{,}2 - 1{,}96 = 0{,}24$; $\overline{y^2} = 0{,}7$, $\sigma_y^2 = 0{,}7 - 0{,}01 = 0{,}69$. Il coefficiente di correlazione è

$$\rho_{xy} = \frac{-0{,}26}{\sqrt{0{,}24 \cdot 0{,}69}} \approx -0{,}64 :$$

quando x cresce, y tende a diminuire. La retta dei minimi quadrati ha pendenza $m = \frac{-0{,}26}{0{,}24} = -\frac{13}{12} \approx -1{,}08$ e intercetta $q = -0{,}1 + \frac{13}{12}\cdot 1{,}4 = \frac{17}{12} \approx 1{,}42$; spiega $R^2 = \rho^2 \approx 41\%$ della variabilità di y (figura 1.2).

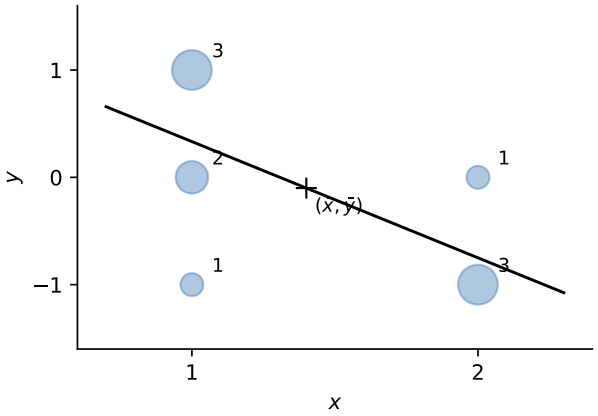


Figura 1.2 · Dati dell’esercizio 4 (l’area dei cerchi è proporzionale alla frequenza) e retta dei minimi quadrati.

Riepilogo

I dati si organizzano per unità sperimentali e variabili, quantitative o qualitative. Una variabile si riassume con la tabella delle frequenze assolute e relative e con un diagramma a barre, a torta o di Pareto; due variabili qualitative con la tabella a due vie, le marginali e i profili riga e colonna, legati alla frequenza congiunta dalla regola del prodotto. Per una variabile quantitativa la media è la somma dei valori pesati con le frequenze ed è sensibile ai valori estremi; la mediana e gli altri quantili si leggono sulla cumulata empirica e sono robusti. Il boxplot mostra quartili, scarto interquartile e valori anomali (fuori da $Q_1 - \frac{3}{2}\mathrm{IQR}$, $Q_3 + \frac{3}{2}\mathrm{IQR}$). La dispersione si misura con varianza e deviazione standard (σ^2 con $\frac{1}{n}$, s^2 con $\frac{1}{n-1}$), che si calcolano come media dei quadrati meno quadrato della media e non cambiano spostando i dati; il coefficiente di variazione le rende confrontabili. Covarianza e correlazione misurano la relazione lineare fra due variabili, con $|\rho| \le 1$; la retta dei minimi quadrati passa per $(\bar{x}, \bar{y})$ con pendenza σ_{xy}/σ_x^2, la sua bontà si misura con $R^2 = \rho^2$ e si controlla con i residui. Le tabelle aggregate possono ingannare (paradosso di Simpson).

2 · Probabilità e variabili aleatorie

In questo modulo. Servono il linguaggio degli insiemi (unione, intersezione, complementare), le serie numeriche e gli integrali, anche impropri, di Analisi 1. Il modulo costruisce il modello matematico dei fenomeni casuali: spazio campionario, eventi, assiomi della probabilità. Si impara a contare i casi con il calcolo combinatorio, a usare la probabilità condizionata, la formula delle probabilità totali e quella di Bayes, e a riconoscere eventi indipendenti. Nella seconda parte si introducono le variabili aleatorie, discrete e con densità, la loro legge e la funzione di ripartizione, e si impara a trovare la legge di una funzione di una variabile aleatoria. Il modulo 3 continua con i valori attesi e le leggi notevoli.

2.1 Esperimenti, eventi, assiomi

Un **esperimento aleatorio** è una procedura che, ripetuta più volte nelle stesse condizioni, produce risultati diversi. L'insieme dei possibili risultati è lo **spazio campionario** Ω. Qualche esempio: lancio di una moneta, $\Omega = \{T, C\}$; lancio di un dado, $\Omega = \{1, \dots, 6\}$; numero di lanci necessari perché esca testa, $\Omega = \mathbb{N} \setminus \{0\}$; altezza di uno studente scelto a caso, $\Omega = \mathbb{R}$ (o un suo intervallo).

Un **evento** è un sottoinsieme $E \subseteq \Omega$, cioè una collezione di possibili risultati. Se il risultato dell'esperimento è ω, si dice che E **si è verificato** se $\omega \in E$, e che non si è verificato se $\omega \notin E$. Gli eventi si combinano con le operazioni sugli insiemi:

- Ω è l'evento **certo**, $\emptyset$ l'evento **impossibile**, $\{\omega\}$ un evento **elementare**;
- l'**opposto** $\bar{E} = \{\omega \in \Omega \mid \omega \notin E\}$ si verifica quando E non si verifica;
- l'**intersezione** $E \cap F$ si verifica quando si verificano entrambi, l'**unione** $E \cup F$ quando se ne verifica almeno uno;
- E e F sono **disgiunti** (incompatibili) se $E \cap F = \emptyset$.

Nel lancio di un dado, con E = "esce un numero pari" $= \{2, 4, 6\}$ e F = "esce un numero primo" $= \{2, 3, 5\}$: se esce 4, E si è verificato e F no; $\bar{E} = \{1, 3, 5\}$, $E \cap F = \{2\}$, $E \cup F = \{2, 3, 4, 5, 6\}$.

Probabilità

Una **probabilità** su Ω associa a ogni evento E un numero $P[E]$ tale che

1. $P[\Omega] = 1$;
2. $0 \le P[E] \le 1$ per ogni evento E;
3. se $E_1, E_2, \dots$ sono eventi a due a due disgiunti, $P[E_1 \cup E_2 \cup \dots] = P[E_1] + P[E_2] + \dots$

La coppia (Ω, P) è uno **spazio di probabilità**.

Conviene pensare a $P[E]$ come all'area di E dentro un quadrato Ω di area 1: le proprietà che seguono diventano evidenti disegnando gli insiemi.

Aggiunta in revisione · fonte: Ross, *Introduzione alla statistica* (STA-01)

Il programma distingue tre modi di assegnare le probabilità. La definizione **classica** vale per esiti equiprobabili: casi favorevoli su casi possibili (paragrafo 2.2). La definizione **a posteriori** (frequentista) prende come probabilità di un evento il limite della sua frequenza relativa quando l'esperimento si ripete molte volte; la legge dei grandi numeri del modulo 3 ne è la giustificazione. La definizione **assiomatica** è quella sopra, che comprende le altre due come casi particolari.

Proprietà della probabilità

1. $P[\emptyset] = 0$ e $P[\bar{E}] = 1 - P[E]$;
2. se $E \subseteq F$ allora $P[E] \le P[F]$;
3. $P[E \cup F] = P[E] + P[F] - P[E \cap F]$;
4. principio di inclusione-esclusione per tre eventi:

$$P[E_1 \cup E_2 \cup E_3] = \sum_i P[E_i] - \sum_{i<j} P[E_i \cap E_j] + P[E_1 \cap E_2 \cap E_3].$$

La 3 si vede scomponendo $E \cup F$ in tre parti disgiunte, $E \setminus F$, $E \cap F$ e $F \setminus E$: sommando $P[E]$ e $P[F]$ si conta due volte l'intersezione. In generale, per n eventi si sommano le probabilità singole, si tolgono quelle delle intersezioni a due, si aggiungono quelle a tre, e così via a segni alterni.

2.2 Spazi finiti ed equiprobabili

Uno spazio di probabilità è **finito** se $\Omega = \{\omega_1, \dots, \omega_N\}$. Allora basta conoscere le probabilità degli eventi elementari $p_i = P[\{\omega_i\}]$, che sono numeri $p_i \ge 0$ con $p_1 + \cdots + p_N = 1$: per l'additività, la probabilità di un evento è la somma delle p_i dei suoi elementi. Per esempio, una moneta truccata ha $P[T] = p$ e $P[C] = q = 1 - p$, con $0 \le p \le 1$; la moneta è equilibrata se $p = q = \frac{1}{2}$.

Lo spazio è **equiprobabile** se tutti i risultati hanno la stessa probabilità: allora $p_i = \frac{1}{N}$ e

$$P[E] = \frac{\#E}{\#\Omega} = \frac{\text{casi favorevoli}}{\text{casi possibili}}.$$

Con un dado equilibrato, $P[\text{pari}] = \frac{3}{6} = 50\%$ e $P[\text{primo}] = \frac{4}{6} \approx 67\%$. La somma di queste due probabilità supera 1, e non c'è contraddizione: i due eventi non sono disgiunti (hanno in comune il 2), e infatti $P[E \cup F] = \frac{1}{2} + \frac{2}{3} - \frac{1}{6} = \frac{5}{6}$.

Scegliere bene lo spazio campionario

Lanciando due dadi, la somma va da 2 a 12, ma lo spazio $\{2, \dots, 12\}$ **non** è equiprobabile. Lo è lo spazio delle 36 coppie ordinate (primo dado, secondo dado). La somma 7 si ottiene con 6 coppie, quindi $P[\text{somma } 7] = \frac{6}{36} = \frac{1}{6}$; la somma 11 con 2 coppie, $(5,6)$ e $(6,5)$, quindi $P = \frac{2}{36} = \frac{1}{18}$.

Con tre dadi la somma 9 e la somma 10 si ottengono entrambe con sei terne non ordinate di numeri, ma contando le permutazioni la 9 ha 25 casi su $6^3 = 216$ e la 10 ne ha 27: $P[9] \approx 11{,}6\%$, $P[10] = \frac{1}{8} = 12{,}5\%$.

2.3 Calcolo combinatorio

Negli spazi equiprobabili tutto si riduce a contare. Si ricordano il **fattoriale** $n! = 1 \cdot 2 \cdots n$, con $0! = 1$, e il **coefficiente binomiale**

$$\binom{n}{k} = \frac{n!}{k!\,(n-k)!}, \qquad 0 \le k \le n.$$

Il problema tipico è: in quanti modi si possono scegliere k oggetti da un'urna che contiene n oggetti distinti? Dipende da due cose: se l'oggetto estratto viene rimesso nell'urna (estrazione **con ripetizione**, lo stesso oggetto può uscire più volte) o no, e se l'ordine conta (**disposizioni**) o no (**combinazioni**).

	Conta l'ordine	**Non conta l'ordine**
Senza ripetizione ($k \le n$)	$n(n-1)\cdots(n-k+1) = \dfrac{n!}{(n-k)!}$	$\dbinom{n}{k}$
Con ripetizione	n^k	$\dbinom{n+k-1}{k}$

Per $k = n$ le disposizioni senza ripetizione sono le **permutazioni**, $n!$. Le combinazioni si ottengono dalle disposizioni dividendo per $k!$, perché ogni gruppo di k oggetti si può ordinare in $k!$ modi.

Proprietà del coefficiente binomiale

$$\binom{n}{0} = \binom{n}{n} = 1, \qquad \binom{n}{k} = \binom{n}{n-k}, \qquad \binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k},$$

$$(a+b)^n = \sum_{k=0}^{n} \binom{n}{k} a^k b^{n-k} \quad \text{(binomio di Newton)}.$$

Urne, lotto, poker

- Un'urna contiene 12 palline rosse e 8 bianche e se ne estraggono 4 senza reimmissione. I casi possibili sono $\binom{20}{4}$; per avere 2 rosse e 2 bianche si scelgono 2 rosse fra 12 e 2 bianche fra 8: $P = \binom{12}{2}\binom{8}{2}/\binom{20}{4} \approx 38\%$.
- Al lotto si estraggono 5 numeri su 90. Un terno secco (tre numeri giocati, tutti estratti) ha probabilità $\binom{87}{2}/\binom{90}{5} = \frac{5\cdot4\cdot3}{90\cdot89\cdot88} = \frac{1}{11748} \approx 8{,}5\cdot10^{-5}$. Se la vincita fosse V volte la posta, il gioco sarebbe equo per $(1-p)\cdot 1 = pV$, cioè $V = \frac{1}{p} - 1 = 11747$; il lotto ne paga 4500.
- A poker si ricevono 5 carte da un mazzo di 52 (13 valori, 4 semi): i casi possibili sono $\binom{52}{5} \approx 2{,}6\cdot10^6$. Una **doppia coppia** si forma scegliendo i due valori delle coppie, $\binom{13}{2}$, i semi di ciascuna coppia, $\binom{4}{2}^2$, e la quinta carta fra le 44 di altro valore: $123\,552$ casi, $P \approx 4{,}8\%$. Un **full** (tris e coppia): $13\cdot12\cdot\binom{4}{3}\binom{4}{2} = 3744$ casi, $P \approx 0{,}14\%$.
- I monomi di grado 6 in tre variabili x, y, z corrispondono a scegliere 6 volte una variabile con ripetizione senza ordine: $\binom{8}{6} = 28$. Quelli che contengono tutte e tre le variabili si ottengono moltiplicando xyz per un monomio di grado 3: $\binom{5}{3} = 10$. Scegliendone uno a caso, $P = \frac{10}{28} = \frac{5}{14} \approx 36\%$.

2.4 Probabilità condizionata

Spesso si sa che un evento E si è verificato e ci si chiede quanto sia probabile un altro evento F. L'informazione riduce lo spazio dei risultati possibili a E.

Probabilità condizionata

Se $P[E] > 0$, la **probabilità di F dato E** è

$$P[F \mid E] = \frac{P[E \cap F]}{P[E]}.$$

Fissato E, la funzione $F \mapsto P[F \mid E]$ è una probabilità (verifica gli assiomi): è la distribuzione di probabilità condizionata al fatto che E si è verificato. Rovesciando la definizione si ottiene la **regola del prodotto** e, iterandola, la **regola della catena**:

$$P[E \cap F] = P[E]\,P[F \mid E], \qquad P[E_1 \cap \cdots \cap E_n] = P[E_1]\,P[E_2 \mid E_1]\cdots P[E_n \mid E_1 \cap \cdots \cap E_{n-1}].$$

Due carte di fiori

Si estraggono due carte da un mazzo di 52. Con E = "la prima è di fiori" e F = "la seconda è di fiori", $P[E] = \frac{13}{52}$ e, sapendo che la prima è di fiori, ne restano 12 su 51: $P[F \mid E] = \frac{12}{51}$. Quindi $P[E \cap F] = \frac{13}{52}\cdot\frac{12}{51}$, lo stesso risultato di $\binom{13}{2}/\binom{52}{2}$.

Il condizionato dell'opposto

In generale $P[F \mid \bar{E}] \neq 1 - P[F \mid E]$. Nell'esempio, $P[F \mid \bar{E}] = \frac{13}{51}$, mentre $1 - P[F \mid E] = \frac{39}{51}$. Vale invece $P[\bar{F} \mid E] = 1 - P[F \mid E]$: si complementa l'evento, non la condizione.

Altri due esempi. Si lancia due volte un dado a 4 facce e si sa che la somma è 4: le coppie possibili sono $(1,3)$, $(2,2)$, $(3,1)$, quindi $P[\text{primo lancio } 3 \mid \text{somma } 4] = \frac{1}{3}$. A poker la probabilità di una scala reale (asso, re, donna,

fante e dieci dello stesso seme) è $\frac{4}{\binom{52}{5}} \approx 1{,}5 \cdot 10^{-6}$; sapendo che la prima carta ricevuta è l'asso di cuori, deve essere la scala reale di cuori e le altre quattro carte sono determinate: $\frac{1}{\binom{51}{4}} \approx 4 \cdot 10^{-6}$, circa $\frac{13}{5}$ volte di più.

2.5 Probabilità totali e formula di Bayes

Una famiglia di eventi $E_1, \dots, E_n$ è una **partizione** di Ω se gli eventi sono a due a due disgiunti e la loro unione è Ω: in ogni prova se ne verifica esattamente uno. Il caso più semplice è la partizione $\{E, \bar{E}\}$.

Formula delle probabilità totali

Se $E_1, \dots, E_n$ è una partizione di Ω, per ogni evento F

$$P[F] = P[F \mid E_1]\,P[E_1] + \cdots + P[F \mid E_n]\,P[E_n].$$

In particolare $P[F] = P[F \mid E]\,P[E] + P[F \mid \bar{E}]\,P[\bar{E}]$.

Basta scrivere F come unione disgiunta degli $F \cap E_i$ e applicare la regola del prodotto. La formula si usa quando l'esperimento avviene in due stadi: prima si verifica uno degli E_i, poi F con una probabilità che dipende da quale. Per la seconda carta di fiori: $P[F] = \frac{12}{51}\cdot\frac{13}{52} + \frac{13}{51}\cdot\frac{39}{52} = \frac{13}{52} = \frac{1}{4}$, come se la prima carta non ci fosse.

Formula di Bayes

Se $E_1, \dots, E_n$ è una partizione e $P[F] > 0$,

$$P[E_k \mid F] = \frac{P[F \mid E_k]\,P[E_k]}{P[F \mid E_1]\,P[E_1] + \cdots + P[F \mid E_n]\,P[E_n]}.$$

La formula "rovescia" il condizionamento: dalle probabilità dell'effetto date le cause si risale alla probabilità di una causa dato l'effetto osservato. Le $P[E_k]$ si dicono probabilità **a priori**, le $P[E_k \mid F]$ **a posteriori**.

Dado e moneta

Si lancia un dado equilibrato e poi una moneta equilibrata tante volte quanto è uscito sul dado. Con E_i = "il dado dà i" e F = "escono 4 teste", si ha $P[F \mid E_i] = 0$ per $i \le 3$ e $P[F \mid E_i] = \binom{i}{4}/2^i$ altrimenti: $\frac{1}{16}$, $\frac{5}{32}$, $\frac{15}{64}$ per $i = 4, 5, 6$. Per le probabilità totali

$$P[F] = \frac{1}{6}\left(\frac{4}{64} + \frac{10}{64} + \frac{15}{64}\right) = \frac{29}{384} \approx 7{,}6\%.$$

Sapendo che sono uscite 4 teste, la probabilità che il dado abbia dato 5 è, per Bayes, $\frac{\frac{1}{6}\cdot\frac{10}{64}}{\frac{29}{384}} = \frac{10}{29} \approx 34\%$.

Exit poll

In un ballottaggio il candidato A prende il 45% dei voti e B il 55%. All'uscita dai seggi risponde al sondaggio il 40% degli elettori di A e il 30% di quelli di B. Con E = "ha votato A" e F = "risponde":

$$P[E \mid F] = \frac{0{,}40 \cdot 0{,}45}{0{,}40 \cdot 0{,}45 + 0{,}30 \cdot 0{,}55} = \frac{180}{345} = \frac{12}{23} \approx 52\%.$$

Il sondaggio darebbe vincente A, che perde: la diversa disponibilità a rispondere distorce il campione.

2.6 Eventi indipendenti

Indipendenza

Due eventi E, F sono **indipendenti** se $P[E \cap F] = P[E]\,P[F]$. Tre eventi E_1, E_2, E_3 sono indipendenti se $P[E_i \cap E_j] = P[E_i]\,P[E_j]$ per ogni $i \neq j$ e inoltre $P[E_1 \cap E_2 \cap E_3] = P[E_1]\,P[E_2]\,P[E_3]$.

Se $P[E] > 0$, l'indipendenza equivale a $P[F \mid E] = P[F]$: sapere che E si è verificato non cambia la probabilità di F. Le prove ripetute di un esperimento (lanci successivi di una moneta, estrazioni con reimmissione) si modellano come indipendenti.

Disgiunti non vuol dire indipendenti

Se E e F hanno probabilità positive e sono disgiunti, $P[E \cap F] = 0 \neq P[E]\,P[F]$: non sono indipendenti, anzi, se si verifica uno l'altro è escluso. Per eventi disgiunti $P[E \cup F] = P[E] + P[F]$; per eventi indipendenti $P[E \cup F] = P[E] + P[F] - P[E]\,P[F]$.

Esempio: una moneta truccata ha probabilità di testa doppia di quella di croce, quindi $P[T] = \frac{2}{3}$, $P[C] = \frac{1}{3}$. Lanciandola 3 volte, l'evento "2 teste e 1 croce" è l'unione disgiunta di TTC, TCT, CTT, e per l'indipendenza dei lanci ciascuno ha probabilità $\left(\frac{2}{3}\right)^2 \cdot \frac{1}{3}$: in totale $3 \cdot \frac{4}{27} = \frac{4}{9}$, contro $\frac{3}{8}$ per una moneta equilibrata.

2.7 Variabili aleatorie e loro legge

Variabile aleatoria

Dato uno spazio di probabilità (Ω, P), una **variabile aleatoria** è una funzione $X : \Omega \to \mathbb{R}$, che associa a ogni risultato ω un numero $X(\omega)$.

Si scrive $\{X \in I\} = \{\omega \in \Omega \mid X(\omega) \in I\}$ per l'evento "X assume un valore in I", e allo stesso modo $\{X = x\}$, $\{X \leq x\}$, $\{X > x\}$. Esempi: il numero di teste in 3 lanci, $X \in \{0, 1, 2, 3\}$; il numero di lanci fino alla prima testa, $X \in \{1, 2, \dots\}$; il tempo di attesa a un call center, $X \in [0, +\infty)$. Un esempio fondamentale è la **variabile indicatrice** di un evento E:

$$1_E(\omega) = \begin{cases} 1 & \omega \in E, \\ 0 & \omega \notin E, \end{cases}$$

che vale 1 in caso di "successo" e 0 di "insuccesso".

Una variabile è **finita** se assume un numero finito di valori $x_1, \dots, x_n$, **discreta** se ne assume un'infinità numerabile $x_1, x_2, \dots$. In entrambi i casi gli eventi $\{X = x_k\}$ formano una partizione di Ω e $X = \sum_k x_k 1_{\{X = x_k\}}$.

Legge di una variabile aleatoria

La **legge** (o distribuzione) di X è la funzione che a ogni insieme $I \subseteq \mathbb{R}$ associa $\mu_X(I) = P[X \in I]$. Per una variabile finita o discreta è determinata dalla **densità discreta** $p_k = P[X = x_k]$, con $p_k \geq 0$ e $\sum_k p_k = 1$, e

$$P[X \in I] = \sum_{k \,:\, x_k \in I} p_k.$$

La legge si rappresenta con una tabella $x_k \mapsto p_k$ o con un grafico a bastoncini. Per il numero di teste in 3 lanci di una moneta equilibrata i valori 0, 1, 2, 3 hanno probabilità $\frac{1}{8}, \frac{3}{8}, \frac{3}{8}, \frac{1}{8}$; con la moneta truccata del paragrafo 2.6, $\frac{1}{27}, \frac{6}{27}, \frac{12}{27}, \frac{8}{27}$.

Due variabili diverse possono avere la stessa legge; si scrive $X \sim Y$. Lanciando due volte una moneta equilibrata, sia X l'indicatrice di "testa al primo lancio" e Y quella di "testa al secondo". Sul risultato (T, C) si ha $X = 1$ e $Y = 0$, quindi $X \neq Y$; ma entrambe valgono 0 o 1 con probabilità $\frac{1}{2}$, quindi $X \sim Y$.

Per una variabile discreta la condizione $\sum p_k = 1$ è la somma di una serie. Per il numero N di lanci di una moneta equilibrata fino alla prima testa, $P[N = n] = \left(\frac{1}{2}\right)^{n-1} \cdot \frac{1}{2} = \frac{1}{2^n}$ ($n - 1$ croci e poi una testa), e infatti $\sum_{n \geq 1} \frac{1}{2^n} = 1$ (in base 2 è $0{,}111\ldots_2 = 1$).

2.8 Variabili con densità

Per grandezze che variano con continuità (tempi, lunghezze, pesi) ogni singolo valore ha probabilità nulla, e la probabilità si assegna agli intervalli con un integrale.

Densità di probabilità

Una variabile aleatoria X ha **densità** f se per ogni $a < b$

$$P[a \le X \le b] = \int_a^b f(x)\,dx,$$

dove f è continua tranne al più in un numero finito di punti $x_1, \dots, x_N$ (in cui l'integrale si intende improprio, come anche agli estremi $\pm\infty$).

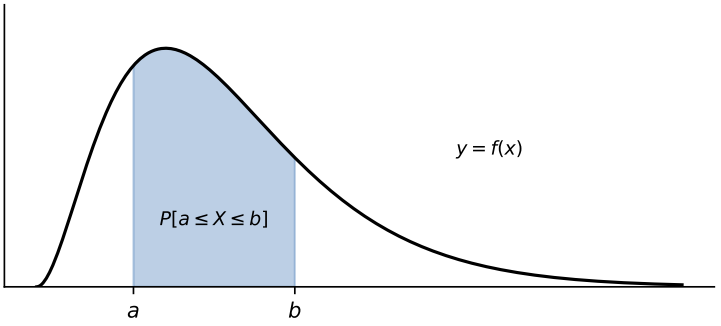


Figura 2.1 · La probabilità che X cada in $[a, b]$ è l'area sotto la densità.

Proprietà delle densità

- $f(x) \ge 0$ e $\int_{-\infty}^{+\infty} f(x)\,dx = 1$;
- $P[X = x] = 0$ per ogni x, quindi includere o no gli estremi non cambia nulla: $P[a \le X \le b] = P[a < X < b]$;
- $P[X \le b] = \int_{-\infty}^{b} f(x)\,dx$ e $P[X \ge a] = \int_{a}^{+\infty} f(x)\,dx$;
- se $f = 0$ fuori da $[m, M]$, allora $m \le X \le M$ con probabilità 1.

Viceversa, ogni funzione non negativa con integrale 1 è la densità di qualche variabile aleatoria. Il valore $f(x)$ non è una probabilità (può essere maggiore di 1): è una "probabilità per unità di lunghezza".

Determinare la costante di una densità

- Un numero estratto uniformemente fra $\frac{1}{2}$ e 1 ha densità costante c su $(\frac{1}{2}, 1)$ e nulla altrove. L'area deve essere 1: $c \cdot \frac{1}{2} = 1$, quindi $c = 2$.
- $f(x) = mx$ per $0 \le x \le 1$, nulla altrove: $\int_0^1 mx\,dx = \frac{m}{2} = 1$ dà $m = 2$. Allora $P[|X| \ge \frac{1}{2}] = P[X \ge \frac{1}{2}] = \int_{1/2}^{1} 2x\,dx = 1 - \frac{1}{4} = \frac{3}{4}$.
- $f(x) = a$ su $[-1, 0]$, $f(x) = b$ su $[1, \frac{3}{2}]$, nulla altrove, con $a, b \ge 0$: la condizione $a + \frac{b}{2} = 1$ dà $b = 2 - 2a$ con $0 \le a \le 1$. C'è una famiglia di densità, non una sola.
- $f(x) = \frac{a}{1+x^2}$ su tutto $\mathbb{R}$: per simmetria $\int f = 2a \lim_{b\to+\infty} \arctan b = a\pi$, quindi $a = \frac{1}{\pi}$ (densità di Cauchy).

2.9 Funzione di ripartizione

Funzione di ripartizione

La **funzione di ripartizione** di X è $F_X(x) = P[X \le x]$, definita per ogni $x \in \mathbb{R}$. Per una variabile discreta $F_X(x) = \sum_{x_k \le x} p_k$; per una variabile con densità $F_X(x) = \int_{-\infty}^{x} f(t)\,dt$.

Nel caso discreto F_X è a gradini, con un salto di altezza p_k in ogni x_k: per il numero di teste in 3 lanci vale 0 per $x < 0$, $\frac{1}{8}$ su $[0, 1)$, $\frac{1}{2}$ su $[1, 2)$, $\frac{7}{8}$ su $[2, 3)$ e 1 per $x \ge 3$. Con densità è una funzione integrale: per X uniforme su $(0, 1)$ vale 0 per $x < 0$, x per $0 \le x \le 1$, 1 per $x > 1$.

Proprietà della funzione di ripartizione

1. F_X è crescente (non decrescente) e $0 \le F_X \le 1$;
2. $\lim_{x\to-\infty} F_X(x) = 0$ e $\lim_{x\to+\infty} F_X(x) = 1$;
3. F_X è continua a destra, e il salto in x_0 è $P[X = x_0]$: $\lim_{x\to x_0^-} F_X(x) = F_X(x_0) - P[X = x_0]$;
4. $P[x_1 < X \le x_2] = F_X(x_2) - F_X(x_1)$;
5. $F_X = F_Y$ se e solo se $X \sim Y$: la funzione di ripartizione determina la legge;
6. se X ha densità f, F_X è continua, è di classe C^1 fuori dai punti di discontinuità $x_1, \dots, x_N$ di f, e lì $F_X' = f$.

Vale anche il viceversa della 6: se F è crescente, con limiti 0 e 1, continua, e di classe C^1 fuori da un numero finito di punti, allora è la funzione di ripartizione di una variabile con densità $f = F'$ (con valori arbitrari nei punti eccezionali). Per esempio $F(x) = 0$ per $x \le 0$, $\sqrt{x}$ per $0 < x < 1$, 1 per $x \ge 1$ ha queste proprietà: è la funzione di ripartizione della densità $f(x) = \frac{1}{2\sqrt{x}}$ su $(0, 1)$.

2.10 Funzioni di variabili aleatorie

Se X è una variabile aleatoria e $\phi : \mathbb{R} \to \mathbb{R}$ una funzione, $Y = \phi(X)$, cioè $Y(\omega) = \phi(X(\omega))$, è un'altra variabile aleatoria. Per esempio: si vincono 2 euro se esce testa e se ne perdono 3 se esce croce; con X l'indicatrice di testa, il bilancio è $Y = 5X - 3$.

Caso discreto. Se X è discreta, anche Y lo è, con valori $\phi(x_k)$ (qualcuno può ripetersi), e

$$P[Y = y] = \sum_{k\,:\,\phi(x_k)=y} P[X = x_k].$$

Un gioco da 11 euro

Si pagano 11 euro per giocare; il banco lancia 4 volte una moneta equilibrata e paga il quadrato del numero di teste più 2 euro per ogni croce. Con X = numero di teste, la vincita netta è $Y = X^2 + 2(4 - X) - 11 = X^2 - 2X - 3$.

x	**0**	**1**	**2**	**3**	**4**
$y = x^2 - 2x - 3$	-3	-4	-3	0	5
$P[X = x]$	$\frac{1}{16}$	$\frac{4}{16}$	$\frac{6}{16}$	$\frac{4}{16}$	$\frac{1}{16}$

I valori $x = 0$ e $x = 2$ danno lo stesso y, quindi la legge di Y è: $P[Y = -4] = \frac{4}{16}$, $P[Y = -3] = \frac{7}{16}$, $P[Y = 0] = \frac{4}{16}$, $P[Y = 5] = \frac{1}{16}$.

Caso con densità. Se X ha densità f_X e ϕ è regolare, si passa per la funzione di ripartizione:

1. si trovano i valori che Y può assumere: se $a \le X \le b$ e ϕ manda $[a, b]$ in $[m, M]$, allora $F_Y(y) = 0$ per $y < m$ e $F_Y(y) = 1$ per $y > M$;
2. per $m < y < M$ si scrive $F_Y(y) = P[\phi(X) \le y] = P[X \in I_y]$, dove $I_y = \{x \mid \phi(x) \le y\}$; di solito I_y è un intervallo $[a, x_2(y)]$ oppure $[x_1(y), x_2(y)]$, e allora $F_Y(y) = F_X(x_2(y))$ oppure $F_X(x_2(y)) - F_X(x_1(y))$;
3. si deriva: $f_Y(y) = F_Y'(y)$, direttamente o con la regola della funzione composta, $f_Y(y) = f_X(x_2(y))\, x_2'(y) - f_X(x_1(y))\, x_1'(y)$.

Una trasformazione lineare

X ha densità $f_X(x) = 2x$ su $(0, 1)$, nulla altrove, e $Y = -3X + 1$. Per $0 \le X \le 1$ si ha $-2 \le Y \le 1$. Per $-2 < y < 1$:

$$F_Y(y) = P[-3X + 1 \le y] = P\left[X \ge \tfrac{1-y}{3}\right] = 1 - F_X\left(\tfrac{1-y}{3}\right) = 1 - \left(\tfrac{1-y}{3}\right)^2,$$

perché $F_X(x) = x^2$ su $[0, 1]$. Derivando, $f_Y(y) = \frac{2}{9}(1 - y)$ su $(-2, 1)$, nulla altrove.

Una trasformazione non monotona

X è uniforme su $(0,1)$ e $Y=(3X-1)^2$, con valori in $[0,4]$. Per $y>0$:

$$F_Y(y)=P\left[-\sqrt{y}\le 3X-1\le\sqrt{y}\right]=P\left[\tfrac{1-\sqrt{y}}{3}\le X\le\tfrac{1+\sqrt{y}}{3}\right].$$

Se $0<y<1$ entrambi gli estremi stanno in $[0,1]$ e $F_Y(y)=\frac{2\sqrt{y}}{3}$; se $1\le y<4$ l'estremo sinistro è negativo e $F_Y(y)=\frac{1+\sqrt{y}}{3}$. Derivando:

$$f_Y(y)=\frac{1}{3\sqrt{y}}\text{ per }0<y<1,\qquad f_Y(y)=\frac{1}{6\sqrt{y}}\text{ per }1<y<4.$$

Non tutte le variabili sono discrete o con densità. Se X è uniforme su $(0,2)$ e $Y=0$ per $X\le 1$, $Y=X-1$ per $X>1$, allora $P[Y=0]=\frac12$ (quindi Y non ha densità), ma per $0<y<1$ si ha $F_Y(y)=\frac{y+1}{2}$, che cresce con continuità (quindi Y non è discreta). La funzione di ripartizione ha un salto di $\frac12$ in 0 e poi una rampa.

Esempi ed esercizi svolti

Esercizio 1 (il problema dei compleanni). In un gruppo di n persone, qual è la probabilità che almeno due compiano gli anni lo stesso giorno? Si suppongono 365 giorni equiprobabili e indipendenti. L'evento opposto è "tutti nati in giorni diversi": il primo può essere nato in qualsiasi giorno, il secondo in 364 su 365, e così via. Per $n\le 365$:

$$p_n=1-\frac{365\cdot 364\cdots(365-n+1)}{365^n}=1-\left(1-\frac{1}{365}\right)\left(1-\frac{2}{365}\right)\cdots\left(1-\frac{n-1}{365}\right).$$

Con $1+x\approx e^x$ per $|x|$ piccolo, il prodotto è circa $e^{-(1+2+\cdots+(n-1))/365}$, quindi $p_n\approx 1-e^{-n(n-1)/730}$. Tutt'altra cosa è la probabilità che qualcuno del gruppo sia nato **nel mio** compleanno: $q_n=1-\left(\frac{364}{365}\right)^n$.

n	**10**	**23**	**30**	**50**
p_n	0,117	0,507	0,706	0,970
$1-e^{-n(n-1)/730}$	0,116	0,500	0,696	0,965
q_n	0,027	0,061	0,079	0,128

Con 23 persone si supera il 50%: il risultato sorprende perché si pensa a q_n invece che a p_n. Per $n=3$ si può anche usare l'inclusione-esclusione sugli eventi E_{ij} = "i e j sono nati lo stesso giorno": $3\cdot\frac{1}{365}-3\cdot\frac{1}{365^2}+\frac{1}{365^2}\approx 0{,}0082$.

Esercizio 2 (coincidenze). Da un'urna con palline numerate da 1 a n se ne estraggono alcune una dopo l'altra senza reimmissione. Qual è la probabilità che alla terza estrazione esca la pallina numero 3? Con la regola della catena: non esce alla prima ($\frac{n-1}{n}$), non esce alla seconda ($\frac{n-2}{n-1}$), esce alla terza ($\frac{1}{n-2}$). Il prodotto è $\frac1n$: ogni pallina ha la stessa probabilità di uscire in ogni posizione. Con $n=10$, $\frac{1}{10}$.

Esercizio 3 (dieci coppie, dieci cabine). Su una nave ci sono 10 cabine doppie prenotate da 10 coppie; all'imbarco le 20 persone sono assegnate alle cabine a caso. Qual è la probabilità che ogni coppia finisca nella stessa cabina? Con la regola della catena, cabina per cabina: la prima cabina riceve una delle 10 coppie con probabilità $\frac{10}{\binom{20}{2}}$, la seconda una delle 9 rimaste con probabilità $\frac{9}{\binom{18}{2}}$, e così via. Il prodotto si semplifica in

$$\frac{10!\,2^{10}}{20!}=\frac{1}{19\cdot 17\cdot 15\cdots 3\cdot 1}\approx 1{,}5\cdot 10^{-9}.$$

Esercizio 4 (una densità a due parametri). Nella densità $f=a$ su $[-1,0]$, $f=b$ su $[1,\frac32]$ del paragrafo 2.8, con $a=\frac12$ si ha $b=1$; allora $P[X>0]=\frac{b}{2}=\frac12$ e $F_X(x)=\frac{x+1}{2}$ su $[-1,0]$, costante $\frac12$ su $[0,1]$, $\frac12+(x-1)$ su $[1,\frac32]$. La funzione di ripartizione è continua, con un tratto piatto dove la densità è nulla.

Riepilogo

Un esperimento aleatorio si modella con uno spazio campionario Ω, i cui sottoinsiemi sono gli eventi, e una probabilità che verifica gli assiomi ($P[\Omega]=1$, valori in $[0,1]$, additività sugli eventi disgiunti); ne seguono la regola

del complementare e l’inclusione-esclusione. Negli spazi equiprobabili la probabilità è casi favorevoli su casi possibili e si calcola con disposizioni ($n!/(n-k)!$ o n^k) e combinazioni ($\binom{n}{k}$ o $\binom{n+k-1}{k}$). La probabilità condizionata $P[F \mid E] = P[E \cap F]/P[E]$ dà la regola del prodotto e della catena, la formula delle probabilità totali su una partizione e la formula di Bayes per risalire dalle osservazioni alle cause. Due eventi sono indipendenti se la probabilità dell’intersezione è il prodotto, il che non ha niente a che fare con l’essere disgiunti. Una variabile aleatoria è una funzione numerica del risultato; la sua legge si descrive con la densità discreta nel caso discreto, con una densità f (non negativa, di integrale 1) nel caso continuo, e in ogni caso con la funzione di ripartizione $F_X(x) = P[X \le x]$, crescente, continua a destra, con $F_X' = f$ dove f è continua. La legge di $Y = \phi(X)$ si trova sommando le probabilità dei valori con la stessa immagine nel caso discreto, e passando per F_Y e derivando nel caso con densità.

3 · Valori attesi, leggi notevoli e teoremi limite

In questo modulo. Si usano le variabili aleatorie, le densità e le funzioni di ripartizione del modulo 2, le serie (geometrica, esponenziale) e l'integrazione per parti di Analisi. Si definiscono la speranza e la varianza di una variabile aleatoria, con le loro proprietà e la disuguaglianza di Chebyshev, la covarianza e la correlazione di due variabili. Poi si studiano le leggi che compaiono più spesso nelle applicazioni (Bernoulli, binomiale, geometrica, Pascal, Poisson, ipergeometrica, uniformi, esponenziale, normale), con il modello da cui nascono, e si impara a usare le tavole della normale, i quantili e i valori critici. Il modulo si chiude con la legge dei grandi numeri e il teorema del limite centrale, che sono il ponte verso l'inferenza del modulo 4.

3.1 Speranza

La **speranza** (valore atteso, media) di una variabile aleatoria è la media dei suoi valori pesata con le probabilità:

Speranza

- Se X è finita o discreta, con valori x_k: $\mathbb{E}[X] = \sum_k x_k \, P[X = x_k]$.
- Se X ha densità f: $\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f(x)\, dx$.

Nel caso di infiniti valori si chiede che la serie o l'integrale converga assolutamente; altrimenti la speranza non esiste (o è infinita).

Speranze elementari

- Numero di teste in due lanci di una moneta con $P[T] = p$: i valori 0, 1, 2 hanno probabilità $(1-p)^2$, $2p(1-p)$, p^2, e $\mathbb{E}[X] = 2p(1-p) + 2p^2 = 2p$.
- Lancio di un dado equilibrato: $\mathbb{E}[X] = \frac{1}{6}(1 + \cdots + 6) = \frac{7}{2}$.
- Densità $f(x) = 2x$ su $(0,1)$: $\mathbb{E}[X] = \int_0^1 2x^2\, dx = \frac{2}{3}$.
- Densità $f(x) = \frac{1}{L} e^{-x/L}$ per $x \geq 0$ (esponenziale, paragrafo 3.6): per parti, $\int_0^{+\infty} \frac{x}{L} e^{-x/L}\, dx = \left[-(x+L)e^{-x/L}\right]_0^{+\infty} = L$.
- Densità $f(x) = \frac{2}{\pi}\frac{1}{1+x^2}$ per $x \geq 0$: $\int_0^{+\infty} \frac{2}{\pi}\frac{x}{1+x^2}\, dx = \frac{1}{\pi}\left[\ln(1+x^2)\right]_0^{+\infty} = +\infty$. La speranza è infinita.

Proprietà della speranza

1. Se $X \sim Y$ allora $\mathbb{E}[X] = \mathbb{E}[Y]$; se $X = c$ costante, $\mathbb{E}[X] = c$.
2. **Linearità**: $\mathbb{E}[aX + bY] = a\,\mathbb{E}[X] + b\,\mathbb{E}[Y]$.
3. **Monotonia**: se $X \geq 0$ allora $\mathbb{E}[X] \geq 0$; se $X \leq Y$ allora $\mathbb{E}[X] \leq \mathbb{E}[Y]$; se $m \leq X \leq M$ allora $m \leq \mathbb{E}[X] \leq M$.
4. Se X e Y sono **indipendenti** (paragrafo 3.4), $\mathbb{E}[XY] = \mathbb{E}[X]\,\mathbb{E}[Y]$.
5. **Formula di trasferimento**: se $Y = \phi(X)$,

$$\mathbb{E}[\phi(X)] = \sum_k \phi(x_k)\, P[X = x_k] \quad \text{oppure} \quad \mathbb{E}[\phi(X)] = \int_{-\infty}^{+\infty} \phi(x) f(x)\, dx.$$

6. **Formula delle code**: se X ha valori in $\mathbb{N}$, $\mathbb{E}[X] = \sum_{n=0}^{\infty} P[X > n]$; se $X \geq 0$ ha densità, $\mathbb{E}[X] = \int_0^{+\infty} P[X > x]\, dx$.

La formula di trasferimento è il modo pratico di calcolare $\mathbb{E}[Y]$ senza trovare la legge di Y. Per esempio, se X è uniforme su $(0, \pi)$, con densità $\frac{1}{\pi}$, e $Y = \sin X$:

$$\mathbb{E}[\sin X] = \int_0^{\pi} \frac{\sin x}{\pi}\, dx = \frac{1}{\pi}\left[-\cos x\right]_0^{\pi} = \frac{2}{\pi}.$$

Passando per la legge si trova lo stesso risultato: per $0 < y < 1$, $\sin X \leq y$ quando $X \leq \arcsin y$ o $X \geq \pi - \arcsin y$, quindi $F_Y(y) = \frac{2}{\pi}\arcsin y$ e $f_Y(y) = \frac{2}{\pi}\frac{1}{\sqrt{1-y^2}}$.

Due lanci di una moneta truccata

Siano X, Y le indicatrici di testa al primo e al secondo lancio, indipendenti con $P[T] = p$. Allora $\mathbb{E}[X] = \mathbb{E}[Y] = p$ e, per linearità, $\mathbb{E}[X + Y] = 2p$ (lo stesso risultato di prima, senza la legge della somma). Inoltre $\mathbb{E}[2XY + 3] = 2\,\mathbb{E}[X]\,\mathbb{E}[Y] + 3 = 2p^2 + 3$, $\mathbb{E}[X^2] = 0^2(1-p) + 1^2 p = p$ e

$$\mathbb{E}\left[\frac{\cos(\pi X)}{1+Y}\right] = \mathbb{E}[\cos(\pi X)]\,\mathbb{E}\left[\frac{1}{1+Y}\right] = (1-2p)\left(1 - \frac{p}{2}\right).$$

Con la formula delle code si trova la speranza del numero N di lanci di una moneta con $P[T] = p$ fino alla prima testa: $N > n$ vuol dire n croci di fila, quindi $P[N > n] = (1-p)^n$ e $\mathbb{E}[N] = \sum_{n \geq 0} (1-p)^n = \frac{1}{p}$.

3.2 Speranza condizionata

Se X e Y sono variabili finite e $P[Y = y_j] > 0$, la **speranza condizionata** di X dato $Y = y_j$ è la speranza di X calcolata con la probabilità condizionata:

$$\mathbb{E}[X \mid Y = y_j] = \sum_k x_k \, P[X = x_k \mid Y = y_j].$$

Formula delle torri

$$\mathbb{E}[X] = \mathbb{E}[X \mid Y = y_1]\,P[Y = y_1] + \cdots + \mathbb{E}[X \mid Y = y_m]\,P[Y = y_m].$$

È la formula delle probabilità totali per le speranze: si calcola la media in ciascun caso e poi la media dei casi.

Un’urna di monete

Un’urna contiene 12 monete equilibrate e 8 truccate con $P[T] = \frac{1}{3}$. Si estrae una moneta e la si lancia 3 volte; X è il numero di teste. Con $Y = 1$ se la moneta è equilibrata (probabilità $\frac{12}{20} = \frac{3}{5}$) e $Y = 0$ altrimenti ($\frac{2}{5}$), il numero medio di teste in 3 lanci è $3 \cdot \frac{1}{2}$ nel primo caso e $3 \cdot \frac{1}{3}$ nel secondo:

$$\mathbb{E}[X] = \frac{3}{2} \cdot \frac{3}{5} + 1 \cdot \frac{2}{5} = \frac{9}{10} + \frac{4}{10} = \frac{13}{10}.$$

Lo stesso ragionamento vale quando il numero di prove è aleatorio. Si lancia un dado equilibrato e poi una moneta con $P[T] = p$ tante volte quanto è uscito sul dado. Sia N l’esito del dado e $S = X_1 + \cdots + X_N$ il numero di teste, con X_i indicatrice di testa all’i-esimo lancio. Se $N = n$ la media è np, quindi

$$\mathbb{E}[S] = \sum_{n=1}^{6} np \cdot \frac{1}{6} = \frac{p}{6} \cdot 21 = \frac{7}{2}p = \mathbb{E}[N]\,\mathbb{E}[X_1].$$

3.3 Varianza e disuguaglianza di Chebyshev

Varianza e deviazione standard

Se $\mu = \mathbb{E}[X]$, la **varianza** di X è $\mathrm{Var}[X] = \mathbb{E}[(X-\mu)^2] = \sigma^2$, e $\sigma = \sqrt{\mathrm{Var}[X]}$ è la **deviazione standard**.

La varianza misura quanto X si allontana in media dalla sua speranza, come la varianza dei dati del modulo 1. Più in generale $\mathbb{E}[X^k]$ è il **momento** di ordine k: la speranza è il momento primo, e la varianza si calcola dai primi due.

Proprietà della varianza

1. $\operatorname{Var}[X] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$;
2. $\operatorname{Var}[aX + b] = a^2 \operatorname{Var}[X]$;
3. se X e Y sono indipendenti, $\operatorname{Var}[X + Y] = \operatorname{Var}[X] + \operatorname{Var}[Y]$;
4. **disuguaglianza di Chebyshev**: per ogni $\varepsilon > 0$, $P[|X - \mu| \geq \varepsilon] \leq \dfrac{\operatorname{Var}[X]}{\varepsilon^2}$.

La disuguaglianza dice qualcosa solo per $\varepsilon > \sigma$ (altrimenti il secondo membro supera 1). Scegliendo $\varepsilon = \sigma/\sqrt{\eta}$ con $0 < \eta < 1$, diventa: con probabilità almeno $1 - \eta$,

$$\mu - \frac{\sigma}{\sqrt{\eta}} < X < \mu + \frac{\sigma}{\sqrt{\eta}}.$$

Per esempio, con probabilità almeno del 75% ($\eta = \frac{1}{4}$) una variabile qualsiasi dista meno di 2σ dalla sua speranza. È una stima grossolana, ma vale per ogni legge.

Varianze elementari

- **Indicatrice** $X = 1_E$ con $P[E] = p$: $X^2 = X$, quindi $\mathbb{E}[X^2] = p$ e $\operatorname{Var}[X] = p - p^2 = p(1 - p)$.
- **Uniforme discreta** su $\{1, \dots, n\}$: $\mathbb{E}[X] = \frac{n+1}{2}$ e $\mathbb{E}[X^2] = \frac{1}{n}\sum k^2 = \frac{(n+1)(2n+1)}{6}$, quindi

  $$\operatorname{Var}[X] = \frac{(n+1)(2n+1)}{6} - \frac{(n+1)^2}{4} = \frac{n+1}{12}(4n + 2 - 3n - 3) = \frac{n^2 - 1}{12}.$$

  Per un dado, $\frac{35}{12}$.
- **Uniforme** su $(0, 1)$: $\mathbb{E}[X] = \frac{1}{2}$, $\mathbb{E}[X^2] = \int_0^1 x^2\,dx = \frac{1}{3}$, $\operatorname{Var}[X] = \frac{1}{3} - \frac{1}{4} = \frac{1}{12}$. Per $Y = (b - a)X + a$, uniforme su (a, b): $\mathbb{E}[Y] = \frac{a+b}{2}$ e $\operatorname{Var}[Y] = \frac{(b-a)^2}{12}$.

3.4 Leggi congiunte, covarianza e correlazione

Due variabili finite X e Y definite sullo stesso spazio hanno una **legge congiunta**, la tabella delle probabilità $P[X = x_i, Y = y_j]$. Come per le tabelle a due vie del modulo 1, le **marginali** si ottengono sommando lungo righe e colonne:

$$P[X = x_i] = \sum_j P[X = x_i, Y = y_j], \qquad P[Y = y_j] = \sum_i P[X = x_i, Y = y_j],$$

e la legge di X condizionata a $Y = y_j$ è il profilo della colonna j, $P[X = x_i \mid Y = y_j] = P[X = x_i, Y = y_j]/P[Y = y_j]$.

Aggiunta in revisione · fonte: Ross, *Introduzione alla statistica*; Devore, *Probability and Statistics for Engineering and the Sciences* (STA-06)

Due variabili aleatorie sono **indipendenti**, e si scrive $X \perp Y$, se per ogni coppia di intervalli I, J gli eventi $\{X \in I\}$ e $\{Y \in J\}$ sono indipendenti. Per variabili discrete basta che la legge congiunta sia il prodotto delle marginali: $P[X = x_i, Y = y_j] = P[X = x_i]\,P[Y = y_j]$ per ogni i, j. Le variabili $X_1, \dots, X_n$ sono indipendenti se gli eventi $\{X_1 \in I_1\}, \dots, \{X_n \in I_n\}$ lo sono per ogni scelta degli intervalli; è il caso dei risultati di prove ripetute nelle stesse condizioni.

Covarianza e coefficiente di correlazione

$$\operatorname{Cov}[X, Y] = \mathbb{E}\big[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])\big], \qquad \rho_{X,Y} = \frac{\operatorname{Cov}[X, Y]}{\sqrt{\operatorname{Var}[X]\operatorname{Var}[Y]}}.$$

Proprietà della covarianza

1. $\mathrm{Cov}[X,Y] = \mathbb{E}[XY] - \mathbb{E}[X]\,\mathbb{E}[Y]$;
2. $\mathrm{Cov}[X,Y] = \mathrm{Cov}[Y,X]$ e $\mathrm{Cov}[X,X] = \mathrm{Var}[X]$;
3. è lineare in ciascun argomento: $\mathrm{Cov}[aX+bY,Z] = a\,\mathrm{Cov}[X,Z] + b\,\mathrm{Cov}[Y,Z]$;
4. $\mathrm{Var}[X+Y] = \mathrm{Var}[X] + 2\,\mathrm{Cov}[X,Y] + \mathrm{Var}[Y]$;
5. $-1 \le \rho_{X,Y} \le 1$ (disuguaglianza di Cauchy-Schwarz);
6. se $X \perp Y$ allora $\mathrm{Cov}[X,Y] = 0$.

Il viceversa della 6 è falso: covarianza nulla non implica indipendenza. Siano $X \in \{-1,0,1\}$ e $Y \in \{0,1\}$ con legge congiunta $P[X=-1,Y=1] = \frac{1}{4}$, $P[X=0,Y=0] = \frac{1}{2}$, $P[X=1,Y=1] = \frac{1}{4}$ (le altre caselle nulle). Allora $\mathbb{E}[X] = 0$, $\mathbb{E}[XY] = -\frac{1}{4} + \frac{1}{4} = 0$, quindi $\mathrm{Cov}[X,Y] = 0$. Ma $P[X=0,Y=1] = 0$ mentre $P[X=0]\,P[Y=1] = \frac{1}{2}\cdot\frac{1}{2}$: le variabili non sono indipendenti (anzi $Y = X^2$).

Covarianza da una legge congiunta

	$Y=0$	$Y=1$	$P[X=x]$
$X=0$	0	$\frac{1}{16}$	$\frac{1}{16}$
$X=1$	$\frac{1}{8}$	$\frac{1}{8}$	$\frac{1}{4}$
$X=2$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{3}{8}$
$X=3$	$\frac{1}{16}$	$\frac{3}{16}$	$\frac{1}{4}$
$X=4$	$\frac{1}{16}$	0	$\frac{1}{16}$
$P[Y=y]$	$\frac{1}{2}$	$\frac{1}{2}$	1

Dalle marginali $\mathbb{E}[X] = \frac{1}{4}+\frac{3}{4}+\frac{3}{4}+\frac{1}{4} = 2$ e $\mathbb{E}[Y] = \frac{1}{2}$. Il prodotto XY è diverso da zero solo nella colonna $Y=1$: $\mathbb{E}[XY] = 1\cdot\frac{1}{8} + 2\cdot\frac{1}{8} + 3\cdot\frac{3}{16} = \frac{15}{16}$. Quindi $\mathrm{Cov}[X,Y] = \frac{15}{16} - 1 = -\frac{1}{16}$.

3.5 Leggi discrete notevoli

Ogni legge nasce da un modello; il modello di riferimento è una moneta con $P[T] = p \in (0,1)$ lanciata più volte, con lanci indipendenti.

Bernoulli $B(p)$

X vale 1 (testa, successo) con probabilità p e 0 con probabilità $1-p$. Ogni indicatrice 1_E è una Bernoulli di parametro $P[E]$. $\mathbb{E}[X] = p$, $\mathrm{Var}[X] = p(1-p)$.

Il prodotto di due Bernoulli indipendenti $B(p_1)$ e $B(p_2)$ è una Bernoulli di parametro $p_1 p_2$, perché vale 1 solo quando valgono 1 entrambe.

Binomiale $\mathrm{Bin}(n,p)$

S_n è il numero di teste in n lanci, cioè $S_n = X_1 + \cdots + X_n$ con $X_i \sim B(p)$ indipendenti. Ha valori $0,\dots,n$ e

$$P[S_n = k] = \binom{n}{k} p^k (1-p)^{n-k}, \qquad \mathbb{E}[S_n] = np, \quad \mathrm{Var}[S_n] = np(1-p).$$

Il coefficiente binomiale conta le posizioni delle k teste fra gli n lanci; speranza e varianza seguono dalla linearità e dall'indipendenza. Se $S_n \sim \mathrm{Bin}(n,p)$ e $S_m \sim \mathrm{Bin}(m,p)$ sono indipendenti, $S_n + S_m \sim \mathrm{Bin}(n+m,p)$: si contano le teste in $n+m$ lanci.

Geometrica $\mathrm{Geo}(p)$

T è il numero di lanci necessari per avere la prima testa (tempo di primo successo). Ha valori $1, 2, \dots$ e

$$P[T = n] = (1-p)^{n-1}p, \qquad P[T > n] = (1-p)^n, \qquad \mathbb{E}[T] = \frac{1}{p}, \quad \mathrm{Var}[T] = \frac{1-p}{p^2}.$$

Vale l'**assenza di memoria**: $P[T > n+k \mid T > n] = P[T > k]$ per ogni $n, k \in \mathbb{N}$.

L'assenza di memoria dice che, se dopo n lanci non è ancora uscita testa, l'attesa che resta ha la stessa legge di quella iniziale: la moneta non "ricorda" le croci passate. Al lotto, un numero ha probabilità $p = \frac{5}{90} = \frac{1}{18}$ di uscire su una ruota a ogni estrazione; la probabilità che non esca per 257 estrazioni di fila è $\left(\frac{17}{18}\right)^{257} \approx 4{,}2 \cdot 10^{-7}$, ma sapendo che non è uscito per 257 volte, la probabilità che non esca neanche alla successiva è ancora $\frac{17}{18} \approx 94\%$. I numeri "ritardatari" non sono più probabili degli altri.

Pascal $\mathrm{Pascal}(k, p)$

T_k è il numero di lanci necessari per avere k teste (tempo del k-esimo successo). Ha valori $k, k+1, \dots$ e

$$P[T_k = n] = \binom{n-1}{k-1}(1-p)^{n-k}p^k, \qquad \mathbb{E}[T_k] = \frac{k}{p}, \quad \mathrm{Var}[T_k] = k\frac{1-p}{p^2}.$$

Inoltre $T_k = U_1 + \cdots + U_k$, dove U_i è il numero di lanci fra il successo $i-1$ e il successo i, e le $U_i \sim \mathrm{Geo}(p)$ sono indipendenti.

Nella formula, l'ultimo lancio è una testa e fra i primi $n-1$ ci sono le altre $k-1$ teste. Gli eventi $\{T_k \le n\}$ e $\{S_n \ge k\}$ coincidono (in n lanci ci sono almeno k teste se e solo se la k-esima è arrivata entro il lancio n).

Poisson $\mathrm{Poisson}(\lambda)$

N ha valori $0, 1, 2, \dots$ e, per un parametro $\lambda > 0$,

$$P[N = k] = e^{-\lambda}\frac{\lambda^k}{k!}, \qquad \mathbb{E}[N] = \mathrm{Var}[N] = \lambda.$$

Se $N \sim \mathrm{Poisson}(\lambda)$ e $M \sim \mathrm{Poisson}(\mu)$ sono indipendenti, $N + M \sim \mathrm{Poisson}(\lambda + \mu)$.

La Poisson è la legge degli **eventi rari**: il numero di successi in moltissime prove, ciascuna con probabilità piccola. Se n è grande e p piccolo, con $\lambda = np$,

$$P[S_n = k] = \frac{n(n-1)\cdots(n-k+1)}{n^k} \cdot \frac{\lambda^k}{k!} \cdot \frac{\left(1-\frac{\lambda}{n}\right)^n}{\left(1-\frac{\lambda}{n}\right)^k} \xrightarrow[n\to\infty]{} e^{-\lambda}\frac{\lambda^k}{k!},$$

perché il primo e l'ultimo fattore tendono a 1 e $\left(1-\frac{\lambda}{n}\right)^n \to e^{-\lambda}$. Si usa per il numero di clienti in un'ora, di accessi a un sito, di guasti in un periodo. Per calcolare più valori di seguito è comoda la relazione $P[N = k] = \frac{\lambda}{k}P[N = k-1]$.

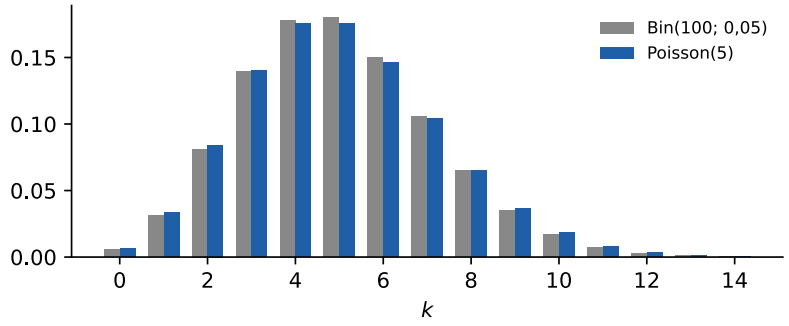


Figura 3.1 · La binomiale $\mathrm{Bin}(100; 0{,}05)$ e la Poisson di parametro 5 sono quasi indistinguibili.

Ipergeometrica $\mathrm{Hyper}(r, b, n)$

Da un'urna con r palline rosse e b bianche se ne estraggono $n \le r + b$ senza reimmissione; $\tilde{S}_n$ è il numero di rosse estratte. Per $k \le r$ e $n - k \le b$:

$$P[\tilde{S}_n = k] = \frac{\binom{r}{k}\binom{b}{n-k}}{\binom{r+b}{n}}, \qquad \mathbb{E}[\tilde{S}_n] = n\frac{r}{r+b}, \quad \mathrm{Var}[\tilde{S}_n] = n\frac{r}{r+b}\cdot\frac{b}{r+b}\cdot\frac{r+b-n}{r+b-1}.$$

Senza reimmissione le estrazioni non sono indipendenti, ma se r e b sono grandi rispetto a n la differenza è trascurabile e l'ipergeometrica è vicina alla binomiale con $p = \frac{r}{r+b}$: la varianza differisce solo per il fattore $\frac{r+b-n}{r+b-1}$, vicino a 1.

Lampadine difettose

Su 1000 lampadine prodotte, 100 sono difettose. In un campione di 10, il numero di difettose è $X \sim \mathrm{Hyper}(100, 900, 10)$, molto vicino a $Y \sim \mathrm{Bin}(10; 0{,}1)$; entrambe hanno speranza 1.

k	**0**	**1**	**2**	**3**	> 3
$P[X = k]$ (ipergeometrica)	34,7%	38,9%	19,4%	5,7%	1,2%
$P[Y = k]$ (binomiale)	34,9%	38,7%	19,4%	5,7%	1,3%

L'**uniforme discreta** su $\{1, \dots, N\}$, modello di un dado equilibrato con N facce, ha $P[X = k] = \frac{1}{N}$, speranza $\frac{N+1}{2}$ e varianza $\frac{N^2-1}{12}$ (paragrafo 3.3).

3.6 Leggi continue notevoli

Uniforme $U[a, b]$

Densità $f(x) = \frac{1}{b-a}$ su $[a, b]$, nulla altrove. Funzione di ripartizione 0 per $x < a$, $\frac{x-a}{b-a}$ su $[a, b]$, 1 per $x > b$. $\mathbb{E}[X] = \frac{a+b}{2}$, $\mathrm{Var}[X] = \frac{(b-a)^2}{12}$. Se $X_0 \sim U[0, 1]$, allora $(b-a)X_0 + a \sim U[a, b]$.

Esponenziale $\mathcal{E}(\lambda)$

Per $\lambda > 0$, densità $f(t) = \lambda e^{-\lambda t}$ per $t \ge 0$, nulla per $t < 0$. Con $\tau = \frac{1}{\lambda}$:

$$F(t) = 1 - e^{-\lambda t}, \quad P[T > t] = e^{-t/\tau}\ (t \ge 0), \qquad \mathbb{E}[T] = \tau, \quad \mathrm{Var}[T] = \tau^2.$$

Vale l'assenza di memoria: $P[T > t + s \mid T > s] = P[T > t]$ per ogni $t, s \ge 0$.

L'esponenziale è il modello dei tempi di attesa senza usura (il tempo fino alla prossima chiamata, la durata di un componente elettronico), ed è l'analogo continuo della geometrica. Il parametro τ è il tempo medio: più è grande, più la densità parte bassa (da $\frac{1}{\tau}$) e decresce lentamente.

Call center

Un call center risponde in media a 12 telefonate l'ora. Il tempo di attesa T fra una chiamata e la successiva si modella come esponenziale con $\mathbb{E}[T] = \frac{60}{12} = 5$ minuti, cioè $\lambda = 0{,}2$ al minuto. La probabilità di aspettare meno di 4 minuti è $P[T \le 4] = 1 - e^{-4/5} \approx 55\%$. Se si è già aspettato 2 minuti, la probabilità di aspettare in tutto meno di 5 è, per l'assenza di memoria, $1 - P[T > 3] = 1 - e^{-3/5} \approx 45\%$.

3.7 La legge normale

Normale standard e normale $N(\mu,\sigma^2)$

La **normale standard** $Z\sim N(0,1)$ ha densità

$$\phi(z)=\frac{1}{\sqrt{2\pi}}e^{-z^2/2},\qquad z\in\mathbb{R}.$$

Per $\mu\in\mathbb{R}$ e $\sigma>0$, $X\sim N(\mu,\sigma^2)$ ha densità $f(x)=\frac{1}{\sqrt{2\pi\sigma^2}}e^{-(x-\mu)^2/(2\sigma^2)}$.

La densità standard è la "curva a campana": simmetrica rispetto a 0, con massimo $\frac{1}{\sqrt{2\pi}}\approx 0{,}40$ in 0 e flessi in ±1. Quella di $N(\mu,\sigma^2)$ ha la stessa forma, centrata in μ, con flessi in $\mu\pm\sigma$. Fra $\mu-\sigma$ e $\mu+\sigma$ cade circa il 68% della probabilità.

Proprietà della normale

1. Se $Z\sim N(0,1)$, allora $X=\sigma Z+\mu\sim N(\mu,\sigma^2)$; viceversa $\frac{X-\mu}{\sigma}\sim N(0,1)$ (**standardizzazione**).
2. $\mathbb{E}[Z]=0$, $\mathrm{Var}[Z]=1$; $\mathbb{E}[X]=\mu$, $\mathrm{Var}[X]=\sigma^2$.
3. Se $X\sim N(\mu,\sigma^2)$ e $a\neq 0$, $aX+b\sim N(a\mu+b,a^2\sigma^2)$.
4. Se $X\sim N(\mu_1,\sigma_1^2)$ e $Y\sim N(\mu_2,\sigma_2^2)$ sono indipendenti, $aX+bY\sim N(a\mu_1+b\mu_2,a^2\sigma_1^2+b^2\sigma_2^2)$.

La funzione di ripartizione della normale standard

$$\Phi(z)=P[Z\le z]=\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{z}e^{-t^2/2}\,dt$$

non si esprime con funzioni elementari e si legge sulle **tavole** (righe per la prima cifra decimale, colonne per la seconda: $\Phi(1{,}24)=0{,}8925$ si trova alla riga 1,2 e alla colonna 0,04).

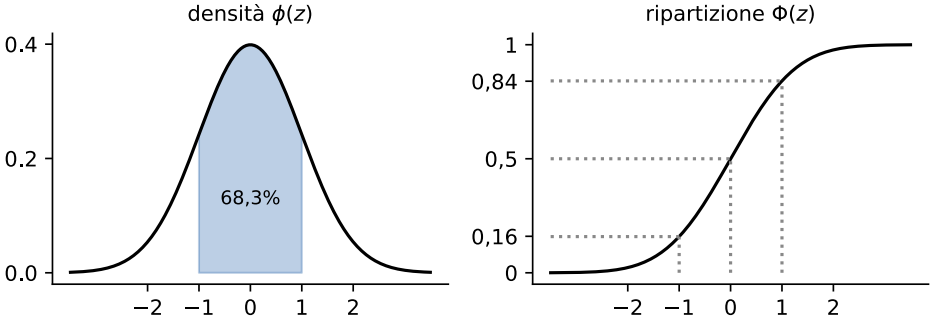


Figura 3.2 · Densità e funzione di ripartizione della normale standard.

Proprietà di Φ

1. $\Phi(0)=\frac12$ e $\Phi(-z)=1-\Phi(z)$ (per simmetria);
2. per $\varepsilon>0$: $P[|Z|\ge\varepsilon]=2\Phi(-\varepsilon)$ e $P[|Z|\le\varepsilon]=2\Phi(\varepsilon)-1$;
3. per $a<b$ e $X\sim N(\mu,\sigma^2)$: $P[a\le X\le b]=\Phi\left(\frac{b-\mu}{\sigma}\right)-\Phi\left(\frac{a-\mu}{\sigma}\right)$;
4. per $z>0$ la coda si maggiora con $\Phi(-z)\le\frac{1}{z\sqrt{2\pi}}e^{-z^2/2}$.

Dimostrazione della 4. Per $t\ge z>0$ si ha $1\le\frac{t}{z}$, quindi

$$\Phi(-z)=P[Z\ge z]=\frac{1}{\sqrt{2\pi}}\int_z^{+\infty}e^{-t^2/2}\,dt\le\frac{1}{\sqrt{2\pi}}\int_z^{+\infty}\frac{t}{z}e^{-t^2/2}\,dt=\frac{1}{z\sqrt{2\pi}}e^{-z^2/2}.\ \square$$

La maggiorazione è grossolana per $z=1$ ($\Phi(-1)\approx 16\%$, la stima dà 24%), ma diventa precisa al crescere di z: per $z=2$, $2{,}3\%$ contro $2{,}7\%$; per $z=3$, $0{,}13\%$ contro $0{,}15\%$; per $z=4$, $0{,}0032\%$ contro $0{,}0034\%$. Le code della normale vanno a zero molto in fretta.

Quantili e valori critici

Per $p \in (0,1)$ il **quantile** φ_p è il numero tale che $P[Z \le \varphi_p] = p$. Per $\alpha \in (0,1)$ il **valore critico** z_α è il numero tale che $P[Z > z_\alpha] = \alpha$. Quindi $z_\alpha = \varphi_{1-\alpha}$.

Per simmetria $\varphi_{1-p} = -\varphi_p$, e $z_\alpha > 0$ se e solo se $\alpha < \frac{1}{2}$. I valori più usati sono $z_{0{,}1} = 1{,}2816$, $z_{0{,}05} = 1{,}6449$, $z_{0{,}025} = 1{,}9600$, $z_{0{,}01} = 2{,}3263$, $z_{0{,}005} = 2{,}5758$. Sulle tavole si cercano a rovescio: $\Phi(1{,}28) = 0{,}8997$ e $\Phi(1{,}29) = 0{,}9015$, quindi $\varphi_{0{,}9} = z_{0{,}1}$ sta fra 1,28 e 1,29.

Uso delle tavole

$X \sim N(1; 0{,}16)$, quindi $\sigma = 0{,}4$. Standardizzando:

$$P[0{,}6 \le X \le 1{,}3] = P\left[-1 \le Z \le 0{,}75\right] = \Phi(0{,}75) - \Phi(-1) = 0{,}7734 - 0{,}1587 = 0{,}6147,$$

$$P[X > 2] = P[Z > 2{,}5] = \Phi(-2{,}5) = 0{,}0062.$$

3.8 Teoremi limite

Siano $X_1, X_2, \ldots$ variabili aleatorie indipendenti e con la stessa legge di una variabile X (si dice **indipendenti e identicamente distribuite**, i.i.d.), con $\mu = \mathbb{E}[X]$ e $\sigma^2 = \mathrm{Var}[X]$. Per la linearità e l'indipendenza, la somma e la media hanno

$$\mathbb{E}[X_1 + \cdots + X_n] = n\mu, \quad \mathrm{Var}[X_1 + \cdots + X_n] = n\sigma^2, \qquad \mathbb{E}\left[\frac{X_1 + \cdots + X_n}{n}\right] = \mu, \quad \mathrm{Var}\left[\frac{X_1 + \cdots + X_n}{n}\right] = \frac{\sigma^2}{n}.$$

La media ha la stessa speranza di una singola osservazione, ma una varianza n volte più piccola.

Legge dei grandi numeri

Per ogni $\varepsilon > 0$,

$$\lim_{n \to \infty} P\left[\left|\frac{X_1 + \cdots + X_n}{n} - \mu\right| \ge \varepsilon\right] = 0.$$

Segue da Chebyshev applicata alla media: la probabilità è al più $\frac{\sigma^2}{n\varepsilon^2}$, che tende a 0. Con X_i indicatrici di un evento, la media è la frequenza relativa dell'evento in n prove, e il teorema dice che si avvicina alla probabilità: è la giustificazione della definizione frequentista.

Teorema del limite centrale

Per ogni $z \in \mathbb{R}$,

$$\lim_{n \to \infty} P\left[\frac{X_1 + \cdots + X_n - n\mu}{\sigma\sqrt{n}} \le z\right] = \Phi(z), \quad \text{cioè} \quad \lim_{n \to \infty} P\left[\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \le z\right] = \Phi(z),$$

dove $\bar{X}_n = \frac{X_1 + \cdots + X_n}{n}$.

Quale che sia la legge di X, per n grande la somma standardizzata è approssimativamente normale: in pratica $X_1 + \cdots + X_n \approx N(n\mu, n\sigma^2)$ e $\bar{X}_n \approx N(\mu, \sigma^2/n)$. È il motivo per cui la normale è così diffusa: le grandezze che nascono dalla somma di molti piccoli effetti indipendenti sono quasi normali.

Una moneta lanciata 100 volte

Sia $Y = \frac{S_{100}}{100}$ la frequenza relativa delle teste in 100 lanci di una moneta equilibrata, quindi $\mu = \frac{1}{2}$ e $\sigma^2 = \frac{1}{4}$. Qual è la probabilità che $|Y - \frac{1}{2}| < \frac{1}{10}$?

- **Calcolo esatto**: è $P[40 < S_{100} < 60] = \sum_{k=41}^{59} \binom{100}{k} 2^{-100} \approx 94{,}3\%$.
- **Chebyshev**: almeno $1 - \frac{\sigma^2}{n\varepsilon^2} = 1 - \frac{1/4}{100 \cdot 1/100} = 75\%$.
- **Teorema del limite centrale**: $P\left[|Z| < \frac{\varepsilon\sqrt{n}}{\sigma}\right] = 2\Phi(2) - 1 \approx 95{,}4\%$.

La stima di Chebyshev è sicura ma pessimista; quella del TLC è approssimata ma vicina al valore vero.

Quando il TLC non basta

Il teorema riguarda $n \to \infty$ con la legge di X fissata. Una variabile $N \sim \text{Poisson}(225)$ è la somma di 225 Poisson(1) indipendenti, quindi è quasi normale: $P[N \le 200] \approx \Phi\left(\frac{200-225}{15}\right) = \Phi(-1{,}67) \approx 4{,}8\%$, contro il valore esatto 4,9%. Ma anche $M \sim \text{Poisson}(1)$ si può scrivere come somma di m Poisson($\frac{1}{m}$) per ogni m grande, e non è affatto normale: $P[M \le 1] = 2e^{-1} \approx 74\%$, mentre la normale darebbe $\Phi(0) = 50\%$. Ciò che conta è che i singoli addendi non dipendano da n, cioè, per la Poisson, che λ sia grande.

Esempi ed esercizi svolti

Esercizio 1 (un dado lanciato 8 volte). Sia S il numero di 6 in 8 lanci: $S \sim \text{Bin}(8, \frac{1}{6})$. Allora $P[S = 2] = \binom{8}{2}\left(\frac{1}{6}\right)^2\left(\frac{5}{6}\right)^6 \approx 0{,}26$, $P[S \ge 2] = 1 - P[S = 0] - P[S = 1] = 1 - \left(\frac{5}{6}\right)^8 - 8 \cdot \frac{1}{6}\left(\frac{5}{6}\right)^7 \approx 0{,}40$, e il numero medio di 6 è $\mathbb{E}[S] = \frac{8}{6} = \frac{4}{3}$.

Esercizio 2 (urna con monete equilibrate e truccate). Un'urna contiene 10 monete, 7 equilibrate e 3 truccate con $P[T] = \frac{2}{3}$. Si estrae una moneta e la si lancia 3 volte. a) Probabilità di 2 teste: per le probabilità totali

$$P[S_3 = 2] = \binom{3}{2}\left(\frac{1}{2}\right)^3 \cdot \frac{7}{10} + \binom{3}{2}\left(\frac{2}{3}\right)^2 \frac{1}{3} \cdot \frac{3}{10} = \frac{21}{80} + \frac{2}{15} = \frac{19}{48} \approx 40\%.$$

b) Sapendo che sono uscite 2 teste, la probabilità che la moneta sia truccata è, per Bayes, $\frac{2/15}{19/48} = \frac{32}{95} \approx 34\%$. c) Numero medio di teste, per la formula delle torri: $\frac{3}{2} \cdot \frac{7}{10} + 2 \cdot \frac{3}{10} = \frac{33}{20}$.

Esercizio 3 (tempi di successo). Una moneta equilibrata viene lanciata ripetutamente. a) La probabilità di 3 teste in 5 lanci è $P[S_5 = 3] = \binom{5}{3}\frac{1}{32} = \frac{10}{32} \approx 31\%$. b) La probabilità che la terza testa arrivi al quinto lancio è $P[T_3 = 5] = \binom{4}{2}\frac{1}{32} = \frac{6}{32} \approx 19\%$. c) La probabilità che la terza testa arrivi entro il quinto lancio è $P[T_3 \le 5] = \frac{1}{8} + \frac{3}{16} + \frac{6}{32} = \frac{1}{2}$, e coincide con $P[S_5 \ge 3] = \frac{10+5+1}{32}$. d) Con $T_1 = U_1$ e $T_2 = U_1 + U_2$, la variabile $X = T_1 + T_2 = 2U_1 + U_2$ ha $\text{Var}[X] = 4\,\text{Var}[U_1] + \text{Var}[U_2] = 5\frac{1-p}{p^2}$, $\text{Cov}[X, T_1] = 2\,\text{Var}[U_1] = 2\frac{1-p}{p^2}$ e, poiché $U_i \ge 1$, $P[X = 4] = P[U_1 = 1,\ U_2 = 2] = p \cdot (1-p)p = p^2(1-p)$.

Esercizio 4 (overbooking). Il 5% di chi compra un biglietto aereo non si presenta all'imbarco. Una compagnia vende 100 biglietti per un aereo da 98 posti. Il numero S di passeggeri che non si presentano è $\text{Bin}(100; 0{,}05)$ e tutti hanno posto se $S \ge 2$:

$$P[S \ge 2] = 1 - 0{,}95^{100} - 100 \cdot 0{,}05 \cdot 0{,}95^{99} \approx 96{,}29\%.$$

Con l'approssimazione di Poisson, $\lambda = 5$: $1 - e^{-5}(1 + 5) \approx 95{,}96\%$.

Esercizio 5 (un sito web). Un sito riceve in media 5 utenti l'ora e si blocca se ne arrivano più di 11. Con $N \sim \text{Poisson}(5)$: $P[N = 12] = e^{-5}\frac{5^{12}}{12!} \approx 3{,}4 \cdot 10^{-3}$, e con la ricorsione $P[N = 13] = \frac{5}{13}P[N = 12] \approx 1{,}3 \cdot 10^{-3}$, $P[N = 14] = \frac{5}{14}P[N = 13] \approx 0{,}5 \cdot 10^{-3}$. Sommando i termini successivi, che decrescono in fretta, $P[N \ge 12] \approx 5{,}5 \cdot 10^{-3}$.

Esercizio 6 (una banca con due sportelli). I clienti in coda ai due sportelli di una banca sono $N_1 \sim \text{Poisson}(8)$ e $N_2 \sim \text{Poisson}(4)$, indipendenti. Il totale $N = N_1 + N_2$ è $\text{Poisson}(12)$, e $P[N = 9] = e^{-12}\frac{12^9}{9!} \approx 8{,}7\%$. Sapendo che i clienti sono n in tutto, il numero di quelli al secondo sportello è binomiale:

$$P[N_2 = k \mid N = n] = \frac{P[N_1 = n-k]\,P[N_2 = k]}{P[N = n]} = \binom{n}{k}\left(\frac{4}{12}\right)^{k}\left(\frac{8}{12}\right)^{n-k}.$$

Esercizio 7 (altezze). L'altezza degli studenti è $X \sim N(\mu, \sigma^2)$ con $\mu = 175$ cm e $\text{Var}[X] = 64$ cm², quindi $\sigma = 8$ cm. a) $P[X > 183] = P[Z > 1] = \Phi(-1) \approx 15{,}9\%$. b) Uno studente è "atipico" se la sua altezza differisce dalla media di più di 10 cm: $P[|X - 175| > 10] = P[|Z| > 1{,}25] = 2\Phi(-1{,}25) \approx 21\%$. c) Il $\delta > 0$ tale che $P[\mu - \delta < X < \mu + \delta] = 50\%$: deve essere $2\Phi\left(\frac{\delta}{\sigma}\right) - 1 = \frac{1}{2}$, cioè $\frac{\delta}{\sigma} = \varphi_{0{,}75} \approx 0{,}6745$ e $\delta \approx 5{,}40$ cm.

Esercizio 8 (biscotti in gita). In gita ogni studente mangia in media 6 biscotti, con deviazione standard 2. Quanti biscotti servono per 81 studenti per essere sicuri al 99% di non restare senza? Il totale S è la somma di 81 variabili indipendenti, quindi per il TLC $S \approx N(81 \cdot 6, 81 \cdot 4) = N(486, 18^2)$. Si cerca m con $P[S \le m] \ge 0{,}99$: $\frac{m - 486}{18} \ge \varphi_{0{,}99} = 2{,}3263$, cioè $m \ge 486 + 41{,}9$. Servono 528 biscotti.

Riepilogo

La speranza è la media dei valori di una variabile pesata con la sua legge; è lineare, monotona, si calcola per le funzioni di X con la formula di trasferimento e, per variabili a valori interi o positive, con la formula delle code. La speranza condizionata e la formula delle torri permettono di calcolarla per casi. La varianza $\mathbb{E}[X^2] - \mathbb{E}[X]^2$ misura la dispersione, scala con a^2, si somma per variabili indipendenti e controlla le code con Chebyshev. Covarianza e correlazione misurano la dipendenza lineare di due variabili; l'indipendenza implica covarianza nulla, non il viceversa. Le leggi discrete notevoli nascono dai lanci di una moneta: Bernoulli, binomiale (numero di successi, np e $np(1-p)$), geometrica e Pascal (tempi di successo, senza memoria la prima), Poisson come limite della binomiale per eventi rari ($\lambda = np$, speranza e varianza λ), ipergeometrica per le estrazioni senza reimmissione. Fra le continue, l'uniforme, l'esponenziale (tempi di attesa senza memoria, media $\tau = 1/\lambda$) e la normale, che si riduce alla standard con $Z = (X - \mu)/\sigma$ e si usa con le tavole di Φ, i quantili φ_p e i valori critici z_α. Per variabili i.i.d. la media ha speranza μ e varianza σ^2/n: per la legge dei grandi numeri si concentra attorno a μ, e per il teorema del limite centrale è approssimativamente $N(\mu, \sigma^2/n)$.

4 · Inferenza: stima, intervalli e test

In questo modulo. Servono le leggi notevoli, la normale con quantili e valori critici, la legge dei grandi numeri e il teorema del limite centrale del modulo 3. Fin qui la legge delle variabili era nota e se ne calcolavano le probabilità; nell'inferenza si fa il percorso inverso: da un campione di dati si ricavano informazioni sui parametri ignoti della popolazione. Si definiscono stimatori corretti e consistenti, si costruiscono intervalli di confidenza per la media (con varianza nota e ignota), per la varianza, per una proporzione e per la differenza di due medie, e si sceglie la numerosità del campione. Si introducono le leggi chi-quadro e t di Student. Le ultime sezioni trattano i test di ipotesi (errori, livello di significatività, p-value, potenza), i test per medie, varianze e tabelle di contingenza, e l'analisi della varianza a una via.

4.1 Campioni, stime e stimatori

Una variabile aleatoria X descrive una grandezza in una **popolazione** (il peso dei pesci di un allevamento, l'esito del lancio di una moneta). La sua legge dipende da un **parametro** θ ignoto, per esempio p se $X \sim B(p)$, oppure in generale $\theta = \mathbb{E}[X]$.

> **Campione, stima, stimatore**
>
> Un **campione** di dimensione n è una famiglia $X_1, \dots, X_n$ di variabili aleatorie indipendenti e con la stessa legge di X. I numeri $x_1, \dots, x_n$ effettivamente osservati sono una **realizzazione** del campione. Una funzione T dei dati dà la **stima** $T(x_1, \dots, x_n)$ del parametro, un numero; la stessa funzione applicata al campione dà lo **stimatore** $\hat{\theta} = T(X_1, \dots, X_n)$, una variabile aleatoria.

Per esempio, n lanci della stessa moneta sono un campione di $X \sim B(p)$; una realizzazione è una sequenza di 0 e 1 come $(1, 0, 1, \dots, 0)$; la frequenza relativa delle teste $\frac{x_1 + \cdots + x_n}{n}$ è una stima di p, e $\hat{p} = \frac{X_1 + \cdots + X_n}{n}$ è lo stimatore corrispondente. La distinzione è essenziale: la stima cambia da un campione all'altro, e le proprietà di uno stimatore descrivono come si comporta "in media" su tutti i campioni possibili.

> **Stimatore corretto e consistente**
>
> Una successione di stimatori $\hat{\theta}_n = T_n(X_1, \dots, X_n)$ è
>
> - **corretta** (non distorta) se $\mathbb{E}[\hat{\theta}_n] = \theta$ per ogni n; la differenza $\mathbb{E}[\hat{\theta}_n] - \theta$ si chiama **distorsione**;
> - **consistente** (in media quadratica) se l'**errore quadratico medio** tende a zero: $\lim_{n \to \infty} \mathbb{E}\big[(\hat{\theta}_n - \theta)^2\big] = 0$.

L'errore quadratico medio si scompone in varianza più quadrato della distorsione:

$$\mathbb{E}\big[(\hat{\theta} - \theta)^2\big] = \operatorname{Var}[\hat{\theta}] + \big(\mathbb{E}[\hat{\theta}] - \theta\big)^2.$$

Per uno stimatore corretto è la sola varianza, quindi uno stimatore corretto è consistente se $\operatorname{Var}[\hat{\theta}_n] \to 0$.

> **Aggiunta in revisione · fonte: Ross, *Introduzione alla statistica* (STA-12)**
>
> Fra due stimatori corretti dello stesso parametro è più **efficiente** quello con varianza minore: a parità di campione, le sue stime si disperdono meno attorno al valore vero. Per esempio, per la media di una popolazione sia X_1 (la prima osservazione) sia $\bar{X}$ sono corretti, ma $\operatorname{Var}[\bar{X}] = \frac{\sigma^2}{n}$ è n volte più piccola di $\operatorname{Var}[X_1] = \sigma^2$.

Gli stimatori più usati sono la **media campionaria** e la **varianza campionaria**:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^{n} X_i, \qquad S^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \bar{X})^2.$$

Proprietà di media e varianza campionaria

Se $\mu = \mathbb{E}[X]$ e $\sigma^2 = \mathrm{Var}[X]$: $\bar{X}$ è uno stimatore corretto e consistente di μ, e S^2 è uno stimatore corretto di σ^2.

Dimostrazione. Per la linearità $\mathbb{E}[\bar{X}] = \frac{1}{n} \cdot n\mu = \mu$, e per l'indipendenza $\mathrm{Var}[\bar{X}] = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n} \to 0$. Per S^2, si osserva che $X_i - \bar{X}$ ha speranza nulla, quindi $\mathbb{E}[(X_i - \bar{X})^2] = \mathrm{Var}[X_i - \bar{X}]$. Scrivendo $X_i - \bar{X} = \left(1 - \frac{1}{n}\right) X_i - \frac{1}{n} \sum_{j \neq i} X_j$, somma di variabili indipendenti,

$$\mathrm{Var}[X_i - \bar{X}] = \left(1 - \frac{1}{n}\right)^2 \sigma^2 + \frac{n-1}{n^2}\sigma^2 = \frac{(n-1)^2 + (n-1)}{n^2}\sigma^2 = \frac{n-1}{n}\sigma^2.$$

Sommando sugli n indici e dividendo per $n - 1$ si ottiene $\mathbb{E}[S^2] = \sigma^2$. $\square$

Con $\frac{1}{n}$ al posto di $\frac{1}{n-1}$ lo stimatore sarebbe distorto: sottostimerebbe la varianza di un fattore $\frac{n-1}{n}$. È il motivo del denominatore $n - 1$ già incontrato nel modulo 1.

4.2 Intervallo di confidenza per la media con varianza nota

Una stima puntuale non dice quanto ci si può fidare. Un **intervallo di confidenza** è un intervallo calcolato dai dati che contiene il parametro con una probabilità fissata in anticipo.

Si supponga $X \sim N(\mu, \sigma^2)$ con μ ignoto e σ^2 noto. Allora $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ e, standardizzando, $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$. Fissato $\alpha \in (0,1)$,

$$P\left[\left|\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right| \leq z_{\alpha/2}\right] = 1 - \alpha,$$

e risolvendo la disuguaglianza rispetto a μ: con probabilità $1 - \alpha$,

$$\bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \leq \mu \leq \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2}.$$

Intervallo di confidenza per la media (varianza nota)

Data una realizzazione con media $\bar{x}$, l'intervallo

$$\left[\bar{x} - \delta,\ \bar{x} + \delta\right], \qquad \delta = z_{\alpha/2}\frac{\sigma}{\sqrt{n}},$$

è l'**intervallo di confidenza** bilatero per μ al **livello di confidenza** $1 - \alpha$.

Che cosa vuol dire "al 95%"

Una volta calcolato sui dati, l'intervallo è fisso, e μ è un numero: o ci sta dentro o no. Non si può dire che "μ sta nell'intervallo con probabilità 95%". Il 95% si riferisce alla procedura: se si ripetesse l'esperimento con molti campioni, circa il 95% degli intervalli così costruiti conterrebbe μ (figura 4.1). Per questo si parla di confidenza e non di probabilità.

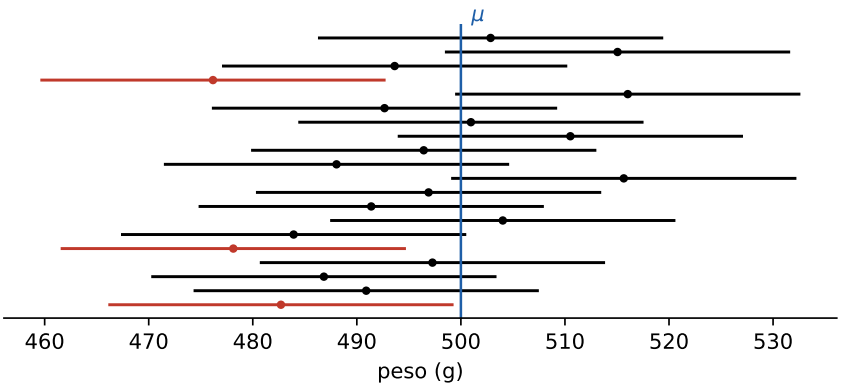


Figura 4.1 · Venti intervalli al 90% calcolati da campioni simulati di 100 pesci con $\mu = 500$ g e $\sigma = 100$ g: tre non contengono μ.

Se X non è normale ma n è grande, per il teorema del limite centrale $\bar{X}$ è approssimativamente $N(\mu, \sigma^2/n)$ e lo stesso intervallo ha livello approssimativamente $1-\alpha$. Senza alcuna ipotesi sulla legge e per ogni n, la disuguaglianza di Chebyshev dà invece l'intervallo $\bar{x} \pm \frac{1}{\sqrt{\alpha}}\frac{\sigma}{\sqrt{n}}$, con livello almeno $1-\alpha$, molto più largo:

$1-\alpha$	**75%**	**90%**	**95%**	**99%**
$\frac{1}{\sqrt{\alpha}}$ (Chebyshev)	2	3,16	4,47	10
$z_{\alpha/2}$ (normale)	1,15	1,645	1,96	2,576

Il peso dei pesci

In un allevamento il peso dei pesci è normale con media ignota e deviazione standard $\sigma = 100$ g. Un campione di 100 pesci ha peso medio 500 g.

- Al 90%: $\alpha = 0{,}1$, $z_{0{,}05} = 1{,}645$, $\delta = 1{,}645 \cdot \frac{100}{10} = 16{,}45$, quindi $484 \le \mu \le 516$ g.
- Al 99%: $z_{0{,}005} = 2{,}576$, $\delta = 25{,}76$, quindi $474 \le \mu \le 526$ g. Più confidenza costa un intervallo più largo.
- Quanto deve essere grande il campione perché l'intervallo al 99% sia largo come quello al 90% con 100 pesci? Deve essere $\frac{2{,}576}{\sqrt{n'}} = \frac{1{,}645}{\sqrt{100}}$, cioè $n' = \left(\frac{2{,}576}{1{,}645}\right)^2 \cdot 100 \approx 245{,}2$: servono 246 pesci.

4.3 Leggi chi-quadro e t di Student

Quando la varianza non è nota la si stima con S^2, e servono le leggi delle quantità che ne risultano.

Leggi chi-quadro e t di Student

Siano $Z_1, \dots, Z_n$, Z normali standard indipendenti.

- La legge di $W_n = Z_1^2 + \cdots + Z_n^2$ è la **chi-quadro con n gradi di libertà**, χ^2_n. Ha valori positivi, $\mathbb{E}[W_n] = n$, $\mathrm{Var}[W_n] = 2n$, ed è asimmetrica (con moda in $\max\{n-2, 0\}$).
- Se $W_n \sim \chi^2_n$ è indipendente da Z, la legge di $T_n = \dfrac{Z}{\sqrt{W_n/n}}$ è la **t di Student con n gradi di libertà**, t_n. È simmetrica, con $\mathbb{E}[T_n] = 0$ per $n \ge 2$ e $\mathrm{Var}[T_n] = \frac{n}{n-2}$ per $n \ge 3$.

La t di Student somiglia alla normale standard ma ha code più spesse, perché al denominatore c'è una quantità aleatoria; al crescere di n si avvicina alla normale, e per n grande $t_{\alpha,n} \approx z_\alpha$ (figura 4.2). Per n grande anche la chi-quadro è quasi normale, $N(n, 2n)$, per il teorema del limite centrale.

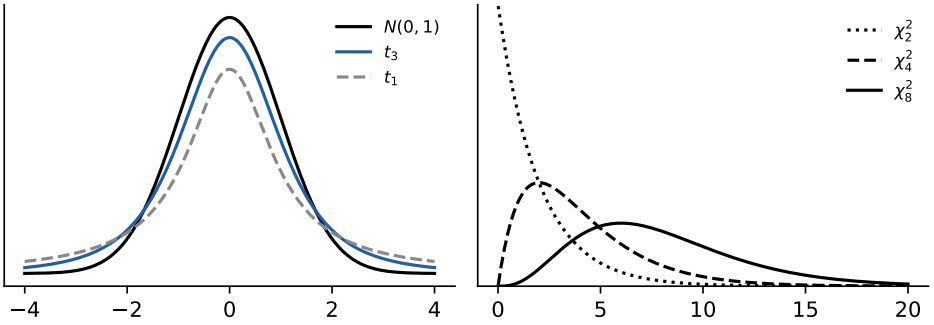


Figura 4.2 · A sinistra la normale standard e le t di Student con 1 e 3 gradi di libertà; a destra le densità chi-quadro con 2, 4, 8 gradi di libertà.

I **valori critici** si definiscono come per la normale, con la coda destra: $P[T_n > t_{\alpha,n}] = \alpha$ e $P[W_n > \chi^2_{\alpha,n}] = \alpha$, e si leggono sulle tavole. Per simmetria $P[-t_{\alpha/2,n} \le T_n \le t_{\alpha/2,n}] = 1-\alpha$; per la chi-quadro, che non è simmetrica, servono due valori: $P[\chi^2_{1-\alpha/2,n} \le W_n \le \chi^2_{\alpha/2,n}] = 1-\alpha$.

Campioni normali

Se $X_1, \dots, X_n$ è un campione di $N(\mu, \sigma^2)$, allora

1. $\dfrac{\bar X - \mu}{S/\sqrt{n}} \sim t_{n-1}$;
2. $\dfrac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$;
3. $\bar X$ e S^2 sono indipendenti.

Si perde un grado di libertà perché gli scarti $X_i - \bar X$ hanno somma nulla. Dal teorema, come nel paragrafo 4.2, si ricavano gli intervalli.

Intervalli per media e varianza di una popolazione normale

Con $\bar x$ e s^2 calcolate sui dati, al livello $1-\alpha$:

$$\bar x - t_{\alpha/2,n-1}\frac{s}{\sqrt{n}} \le \mu \le \bar x + t_{\alpha/2,n-1}\frac{s}{\sqrt{n}}, \qquad \frac{(n-1)s^2}{\chi^2_{\alpha/2,n-1}} \le \sigma^2 \le \frac{(n-1)s^2}{\chi^2_{1-\alpha/2,n-1}}.$$

L'intervallo per σ^2 non è simmetrico attorno a s^2. Per n grande $t_{\alpha/2,n-1} \approx z_{\alpha/2}$ e l'intervallo per la media è quasi quello con varianza nota, con s al posto di σ.

Pezzi venduti in un'ora

Il numero di pezzi venduti in una certa ora del giorno è normale. In 9 giorni si osservano media $\bar x = 200$ e deviazione standard campionaria $s = 13$. Intervalli al 98% ($\alpha = 0{,}02$, $\frac{\alpha}{2} = 0{,}01$, 8 gradi di libertà):

- per μ: $t_{0{,}01;8} = 2{,}896$, $\delta = 2{,}896 \cdot \frac{13}{3} \approx 12{,}6$, quindi $187{,}4 \le \mu \le 212{,}6$. Usando per errore la normale ($z_{0{,}01} = 2{,}326$) si troverebbe $\delta \approx 10$: con soli 9 dati la differenza conta;
- per σ^2: $\chi^2_{0{,}99;8} = 1{,}646$ e $\chi^2_{0{,}01;8} = 20{,}090$, quindi $\frac{8\cdot 169}{20{,}090} \le \sigma^2 \le \frac{8\cdot 169}{1{,}646}$, cioè $67{,}3 \le \sigma^2 \le 821{,}1$ e $8{,}2 \le \sigma \le 28{,}7$. Con pochi dati la varianza è stimata male.

4.4 Intervalli per una proporzione e numerosità del campione

Sia $X \sim B(p)$ con p ignoto (la frazione di pezzi difettosi, di elettori di un partito) e $\hat p = \frac{X_1 + \dots + X_n}{n}$ la frequenza relativa dei successi. Per il teorema del limite centrale $\hat p \approx N\left(p, \frac{p(1-p)}{n}\right)$, ma la varianza dipende da p, che è ignoto. Ci sono due modi di aggirare il problema:

Intervalli per una proporzione

Al livello approssimato $1-\alpha$:

$$J_1 = \left[\hat{p} - \delta_1,\ \hat{p} + \delta_1\right], \quad \delta_1 = \frac{z_{\alpha/2}}{2\sqrt{n}}; \qquad J_2 = \left[\hat{p} - \delta_2,\ \hat{p} + \delta_2\right], \quad \delta_2 = z_{\alpha/2}\frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}.$$

J_1 usa la maggiorazione $p(1-p) \le \frac{1}{4}$, quindi è prudente (più largo); J_2 sostituisce p con la stima $\hat{p}$.

Una moneta sospetta

Una moneta lanciata 100 volte dà 60 teste: $\hat{p} = 0{,}6$ e $\sqrt{\hat{p}(1-\hat{p})} \approx 0{,}490$.

- Al 90% ($\alpha = 0{,}1$, $z_{0{,}05} = 1{,}645$): $\delta_2 \approx 0{,}081$, $J_2 = [0{,}519;\ 0{,}681]$; $\delta_1 \approx 0{,}082$, $J_1 = [0{,}518;\ 0{,}682]$.
- Al 99% ($z_{0{,}005} = 2{,}576$): $\delta_2 \approx 0{,}126$, $J_2 = [0{,}474;\ 0{,}726]$; $\delta_1 \approx 0{,}129$, $J_1 = [0{,}471;\ 0{,}729]$.

Al 90% l'intervallo esclude $\frac{1}{2}$, al 99% no: i dati sono un indizio, non una prova, che la moneta sia truccata. Se le teste fossero 90, al 99% si avrebbe $J_2 = [0{,}823;\ 0{,}977]$ e $J_1 = [0{,}771;\ 1{,}029]$: quando $\hat{p}$ è vicino a 0 o a 1, J_1 è troppo prudente ed esce perfino da $[0, 1]$.

Numerosità del campione. Spesso si fissa in anticipo la precisione voluta: si vuole che la stima differisca dal valore vero meno di ε con probabilità almeno $1-\alpha$. Basta che sia $\delta = z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \le \varepsilon$, cioè

$$n \ge \frac{z_{\alpha/2}^2\,\sigma^2}{\varepsilon^2},$$

da arrotondare all'intero superiore. Per una proporzione, se non si sa nulla di p, si usa $\sigma^2 = \frac{1}{4}$. Con Chebyshev, invece, $n \ge \frac{\sigma^2}{\alpha\varepsilon^2}$.

Quanti lanci?

Quanti lanci di una moneta equilibrata servono perché la frequenza relativa delle teste differisca da $\frac{1}{2}$ meno di $\frac{1}{100}$ con probabilità almeno del 90%? Con Chebyshev, $n \ge \frac{1/4}{0{,}1 \cdot 10^{-4}} = 25\,000$. Con il teorema del limite centrale, $n \ge \frac{1{,}645^2 \cdot \frac{1}{4}}{10^{-4}} \approx 6765$.

4.5 Differenza di due medie

Aggiunta in revisione · fonte: Ross, *Introduzione alla statistica*; Devore, *Probability and Statistics for Engineering and the Sciences* (STA-13)

Spesso si confrontano due popolazioni (due macchine, due terapie, due classi) con medie μ_1 e μ_2, e interessa $\mu_1 - \mu_2$.

Campioni indipendenti, varianze note o campioni grandi. Con campioni di dimensioni n_1, n_2 e medie $\bar{x}_1$, $\bar{x}_2$, la differenza $\bar{X}_1 - \bar{X}_2$ è (approssimativamente) normale con varianza $\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}$, e l'intervallo al livello $1-\alpha$ è

$$\bar{x}_1 - \bar{x}_2 \pm z_{\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}},$$

dove per campioni grandi le varianze ignote si sostituiscono con s_1^2, s_2^2.

Campioni indipendenti normali, varianze ignote ma uguali. Si stima la varianza comune con la **varianza combinata** $s_p^2 = \frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}$, e si usa la t di Student con $n_1 + n_2 - 2$ gradi di libertà:

$$\bar{x}_1 - \bar{x}_2 \pm t_{\alpha/2,\,n_1+n_2-2}\; s_p\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}.$$

Campioni appaiati. Se i dati sono coppie misurate sulla stessa unità (prima e dopo un trattamento, due strumenti sullo stesso pezzo), non sono indipendenti. Si calcolano le differenze $d_i = x_i - y_i$ e si tratta $d_1, \dots, d_n$ come un solo campione: l'intervallo per $\mu_1 - \mu_2$ è $\bar{d} \pm t_{\alpha/2, n-1}\frac{s_d}{\sqrt{n}}$.

Esempio. Due linee producono pezzi; su 40 pezzi della prima la media di una misura è 52 (con $\sigma_1^2 = 36$), su 50 della seconda è 48 ($\sigma_2^2 = 25$). L'errore standard della differenza è $\sqrt{\frac{36}{40} + \frac{25}{50}} = \sqrt{1{,}4} \approx 1{,}18$ e l'intervallo al 95% è $4 \pm 1{,}96 \cdot 1{,}18$, cioè $[1{,}7;\ 6{,}3]$: non contiene 0, quindi le due linee differiscono.

4.6 Test di ipotesi

Aggiunta in revisione · fonte: Ross, *Introduzione alla statistica*; Newbold, Carlson, Thorne, *Statistica* (STA-14)

Un **test di ipotesi** decide, sulla base di un campione, fra due affermazioni sul parametro: l'**ipotesi nulla** H_0 (per esempio $\mu = \mu_0$, "la media dichiarata è vera") e l'**ipotesi alternativa** H_1, bilatera ($\mu \neq \mu_0$) o unilatera ($\mu > \mu_0$ oppure $\mu < \mu_0$). Si calcola una **statistica test**, una funzione del campione di cui si conosce la legge quando H_0 è vera, e si rifiuta H_0 se il suo valore cade nella **regione di rifiuto**, cioè è troppo improbabile sotto H_0.

Le decisioni possibili hanno due tipi di errore:

	H_0 **vera**	H_0 **falsa**
Si accetta H_0	corretto	errore di II tipo (probabilità β)
Si rifiuta H_0	errore di I tipo (probabilità α)	corretto (probabilità $1-\beta$)

Il **livello di significatività** α è la probabilità massima di errore di I tipo che si accetta, fissata prima di guardare i dati (tipicamente 5% o 1%). La **potenza** $1-\beta$ è la probabilità di rifiutare H_0 quando è falsa, e dipende dal vero valore del parametro: cresce quando questo si allontana da μ_0 e quando cresce n. Le due ipotesi non sono simmetriche: si rifiuta H_0 solo con evidenza forte, e "accettare" H_0 vuol dire solo che i dati non bastano a rifiutarla.

Il **p-value** è la probabilità, calcolata sotto H_0, di osservare un valore della statistica almeno altrettanto estremo di quello osservato. Si rifiuta H_0 al livello α se e solo se il p-value è minore di α; il p-value dice quindi, in un solo numero, per quali livelli i dati portano a rifiutare.

Test sulla media, varianza nota. Per $H_0 : \mu = \mu_0$ la statistica è $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$, normale standard sotto H_0. Al livello α si rifiuta se $|z| > z_{\alpha/2}$ (alternativa bilatera), se $z > z_\alpha$ (alternativa $\mu > \mu_0$), se $z < -z_\alpha$ (alternativa $\mu < \mu_0$). Il test bilatero al livello α rifiuta esattamente quando μ_0 non sta nell'intervallo di confidenza al livello $1-\alpha$.

Esempio (potenza). Per i pesci del paragrafo 4.2 ($\sigma = 100$, $n = 100$) si sottopone a test $H_0 : \mu = 500$ contro $H_1 : \mu > 500$ al 5%. Si rifiuta se $\bar{x} > 500 + 1{,}645 \cdot 10 = 516{,}45$. Se in realtà $\mu = 520$, la probabilità di rifiutare è $P\left[Z > \frac{516{,}45 - 520}{10}\right] = \Phi(0{,}355) \approx 64\%$: con questo campione una differenza di 20 g sfugge in più di un caso su tre.

4.7 Test per medie, proporzioni, varianze e tabelle

Aggiunta in revisione · fonte: Ross, *Introduzione alla statistica*; Devore, *Probability and Statistics for Engineering and the Sciences* (STA-15)

Tutti i test seguono lo schema del paragrafo 4.6; cambiano la statistica e la sua legge sotto H_0.

Ipotesi nulla	Statistica	Legge sotto H_0
$\mu = \mu_0$, varianza ignota, popolazione normale	$T = \dfrac{\bar{X} - \mu_0}{S/\sqrt{n}}$	t_{n-1}
$p = p_0$, n grande	$Z = \dfrac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$	circa $N(0,1)$
$\sigma^2 = \sigma_0^2$, popolazione normale	$W = \dfrac{(n-1)S^2}{\sigma_0^2}$	χ^2_{n-1}
$\mu_1 = \mu_2$, campioni indipendenti	$\dfrac{\bar{X}_1 - \bar{X}_2}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}$ oppure con s_p	$N(0,1)$ oppure $t_{n_1+n_2-2}$
$\mu_1 = \mu_2$, campioni appaiati	$\dfrac{\bar{D}}{S_D/\sqrt{n}}$	t_{n-1}

Esempio (media, varianza ignota). Per le ore di straordinario dell'esercizio 1 in fondo al modulo ($n = 81$, $\bar{x} = 24$, $s = 6$), l'azienda dichiara una media di 25,5 ore. Con $H_0 : \mu = 25{,}5$ contro $\mu \neq 25{,}5$: $t = \frac{24 - 25{,}5}{6/9} = -2{,}25$. Al 5% il valore critico è $t_{0{,}025;80} = 1{,}990$ e si rifiuta H_0; all'1% è $t_{0{,}005;80} = 2{,}639$ e non si rifiuta. Il p-value è circa 2,7%.

Esempio (proporzione). Per la moneta con 60 teste su 100, $H_0 : p = \frac{1}{2}$: $z = \frac{0{,}6 - 0{,}5}{0{,}5/10} = 2$, con p-value $2\Phi(-2) \approx 4{,}6\%$. Si rifiuta al 5%, non all'1%, in accordo con gli intervalli del paragrafo 4.4.

Esempio (varianza). Per i pezzi venduti del paragrafo 4.3 ($n = 9$, $s^2 = 169$), $H_0 : \sigma^2 = 100$ contro $\sigma^2 > 100$: $w = \frac{8 \cdot 169}{100} = 13{,}52$, minore di $\chi^2_{0{,}05;8} = 15{,}507$. Al 5% non si rifiuta.

Test chi-quadro di indipendenza. Per una tabella a due vie con m righe e k colonne si sottopone a test H_0: "le due variabili sono indipendenti". Sotto H_0 la frequenza attesa della casella (i, j) è $e_{ij} = \frac{n_{i\cdot}\, n_{\cdot j}}{n}$, e la statistica

$$\chi^2 = \sum_{i,j} \frac{(n_{ij} - e_{ij})^2}{e_{ij}}$$

ha approssimativamente legge $\chi^2_{(m-1)(k-1)}$ se tutte le e_{ij} sono almeno 5. Si rifiuta per valori grandi. Per la tabella genere × colore degli occhi del modulo 1 le frequenze attese sono 3,6, 5,6, 10,8 per le donne e 5,4, 8,4, 16,2 per gli uomini, e $\chi^2 \approx 4{,}85$ con 2 gradi di libertà: minore di $\chi^2_{0{,}05;2} = 5{,}991$, quindi al 5% non si rifiuta l'indipendenza (p-value circa 9%). Una frequenza attesa è sotto 5, e l'approssimazione va presa con cautela.

4.8 Analisi della varianza a una via

Aggiunta in revisione · fonte: Ross, *Introduzione alla statistica*; Devore, *Probability and Statistics for Engineering and the Sciences* (STA-16)

L'**ANOVA** (*analysis of variance*) confronta le medie di $k \geq 2$ gruppi in un solo test, con $H_0 : \mu_1 = \cdots = \mu_k$ contro "almeno due medie sono diverse". Si suppone che in ogni gruppo i dati siano normali con la stessa varianza σ^2, e che i gruppi siano indipendenti. Siano n_i e $\bar{x}_i$ la numerosità e la media del gruppo i, $N = n_1 + \cdots + n_k$ e $\bar{x}$ la media generale. La variabilità totale si scompone in quella **fra i gruppi** e quella **entro i gruppi**:

$$\underbrace{\sum_{i,j} (x_{ij} - \bar{x})^2}_{SS_T} = \underbrace{\sum_{i} n_i (\bar{x}_i - \bar{x})^2}_{SS_B} + \underbrace{\sum_{i,j} (x_{ij} - \bar{x}_i)^2}_{SS_W}.$$

Sotto H_0 la statistica

$$F = \frac{SS_B/(k-1)}{SS_W/(N-k)}$$

ha legge **F di Fisher** con $(k-1, N-k)$ gradi di libertà, e si rifiuta H_0 se $F > F_{\alpha;\,k-1,\,N-k}$ (dalle tavole di Fisher). L'idea: se le medie sono uguali, la dispersione fra le medie dei gruppi deve essere confrontabile con quella dentro i gruppi; se è molto più grande, le medie differiscono.

Esempio. Tre gruppi di tre misure: (20, 22, 24), (25, 27, 26), (21, 23, 22), con medie 22, 26, 22 e media generale $\frac{70}{3}$. Si trova $SS_B = 32$ e $SS_W = 8 + 2 + 2 = 12$, quindi $F = \frac{32/2}{12/6} = 8$, maggiore di $F_{0{,}05;2,6} = 5{,}14$: al 5% le medie non sono tutte uguali. Con due soli gruppi l'ANOVA equivale al test t con varianza combinata.

Esempi ed esercizi svolti

Esercizio 1 (ore di straordinario). Le ore mensili di straordinario dei dipendenti di un'azienda sono normali. In un campione di 81 dipendenti si trovano $\bar{x} = 24$ e $s = 6$. Intervalli al 99% ($\alpha = 0{,}01$, 80 gradi di libertà). Per la media: $t_{0{,}005;80} = 2{,}639$, $\varepsilon = 2{,}639 \cdot \frac{6}{9} \approx 1{,}759$, quindi $22{,}24 \leq \mu \leq 25{,}76$; con la normale, $z_{0{,}005} = 2{,}576$ e $22{,}28 \leq \mu \leq 25{,}72$, quasi uguale perché n è grande. Per la varianza: $\chi^2_{0{,}995;80} = 51{,}172$ e $\chi^2_{0{,}005;80} = 116{,}321$, quindi

$$\frac{80 \cdot 36}{116{,}321} \leq \sigma^2 \leq \frac{80 \cdot 36}{51{,}172}, \qquad 24{,}76 \leq \sigma^2 \leq 56{,}28, \qquad 4{,}98 \leq \sigma \leq 7{,}50.$$

Esercizio 2 (scegliere l'intervallo giusto). Lo schema degli intervalli al livello $1 - \alpha$:

Situazione	Stimatore	Intervallo
Proporzione, $X \sim B(p)$, n grande	$\hat{p}$	$\hat{p} \pm z_{\alpha/2} \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}$
Media, varianza nota σ_0^2 (normale, o n grande)	$\bar{x}$	$\bar{x} \pm z_{\alpha/2} \frac{\sigma_0}{\sqrt{n}}$
Media, varianza ignota, popolazione normale	$\bar{x}$, s^2	$\bar{x} \pm t_{\alpha/2,n-1} \frac{s}{\sqrt{n}}$
Varianza, popolazione normale	s^2	$\left[\frac{(n-1)s^2}{\chi^2_{\alpha/2,n-1}},\ \frac{(n-1)s^2}{\chi^2_{1-\alpha/2,n-1}}\right]$

Per un campione grande di una popolazione qualsiasi con varianza ignota si usa la seconda riga con s al posto di σ_0.

Riepilogo

Un campione è una famiglia di variabili i.i.d. con la legge della popolazione; uno stimatore è una funzione del campione, corretto se ha speranza uguale al parametro, consistente se l'errore quadratico medio (varianza più distorsione al quadrato) tende a zero, più efficiente di un altro se ha varianza minore. La media campionaria e la varianza campionaria con $n-1$ sono stimatori corretti di μ e σ^2. Un intervallo di confidenza al livello $1-\alpha$ è costruito in modo che la procedura contenga il parametro nella frazione $1-\alpha$ dei campioni: per la media con varianza nota è $\bar{x} \pm z_{\alpha/2}\sigma/\sqrt{n}$ (esatto per popolazioni normali, approssimato per n grande), con varianza ignota

$\bar{x} \pm t_{\alpha/2,n-1} s/\sqrt{n}$, per la varianza si usano due valori critici della chi-quadro, per una proporzione $\hat{p} \pm z_{\alpha/2}\sqrt{\hat{p}(1-\hat{p})/n}$ o la versione prudente con $\frac{1}{2\sqrt{n}}$. La numerosità per una precisione ε è $n \geq z_{\alpha/2}^2 \sigma^2/\varepsilon^2$. Per due medie si usano le differenze, con la varianza combinata o con i dati appaiati. Un test di ipotesi rifiuta H_0 quando la statistica test cade nella regione di rifiuto, con probabilità di errore di I tipo α; la potenza è la probabilità di rifiutare quando H_0 è falsa, e il p-value è il più piccolo livello a cui i dati portano a rifiutare. Gli stessi schemi danno i test per media, proporzione, varianza, differenza di medie, il test chi-quadro di indipendenza per le tabelle a due vie e l'ANOVA a una via, che confronta più medie con la statistica F.